

Clustering: valor neto y devoluciones

Memoria de clustering: segmentación basada en valor neto y devoluciones

Análisis de clientes, modelos de clustering y estrategia de marketing basada en devoluciones. Esta memoria documenta una nueva línea de trabajo del proyecto: la integración del dataset de ventas con el dataset de devoluciones para identificar clientes más valiosos, detectar fricción comercial y analizar productos asociados a devoluciones. El objetivo principal no es solo segmentar por volumen de compra, sino por valor neto real, considerando el impacto de las devoluciones en la rentabilidad.

Índice

1. Introducción y objetivo del análisis
2. Preparación, comparación y validación de datasets
3. Limpieza de datos y tratamiento de incidencias
4. Feature engineering a nivel cliente
5. Exploración de variables, correlaciones y transformaciones
6. Entrenamiento y evaluación de modelos de clustering
7. Selección del modelo final y segmentos de clientes
8. Estrategias de marketing por segmento
9. Análisis de productos devueltos
10. Estrategia de marketing basada en productos con devolución
11. Conclusiones finales

1. Introducción y objetivo del análisis

Esta fase amplía el análisis de clustering inicial mediante la incorporación del dataset de devoluciones. En lugar de segmentar a los clientes solo por compras, se incorpora el efecto económico de los productos devueltos para calcular el valor neto real del cliente.

El objetivo es detectar clientes de alto valor que compran más y devuelven menos, clientes con fricción por devoluciones y productos que pueden estar generando incidencias o expectativas no cumplidas. Esta aproximación permite construir una segmentación más útil para marketing, fidelización, retención y control de rentabilidad.

- Dataset de ventas: registros positivos de compra.
- Dataset de devoluciones: registros negativos, asociados a facturas de tipo cancelacion.
- Unidad principal de análisis: cliente, identificado mediante CustomerID.
- Unidad complementaria de análisis: producto, identificado mediante Stock Code and Description.

2. Preparación, comparación y validación de datasets

La primera fase consistió en cargar los dos datasets desde Drive, revisar tipos de datos, comprobar nulos, duplicados, signos económicos y coherencia temporal. Se verificó que las ventas tuvieran cantidades e importes positivos y que las devoluciones mantuvieran cantidades e importes negativos antes de convertirlos a magnitudes positivas para el análisis comparativo.

En la comparación inicial se detectó que el dataset de ventas contenía 131.410 registros sin CustomerID, equivalentes al 25,17%. En devoluciones se detectaron 154 registros sin CustomerID, equivalentes al 1,90%. Para clustering por cliente, estos registros no pueden utilizarse, ya que no permiten construir una trayectoria individual de compra y devolución.




Figura 1. Registros conservados y eliminados por ausencia de CustomerID.




Figura 2. Porcentaje de registros conservados y eliminados por ausencia de CustomerID.

Tras la limpieza de CustomerID, se conservaron 390.600 registros de ventas y 7.954 registros de devoluciones. Posteriormente se excluye el concepto administrativo Next Day Carriage, por tratarse de un coste de envío y no de un producto comercial comparable. El dataset final usado en productos contiene 390.521 registros de ventas y 7.953 registros de devoluciones.




Figura 3. Distribución de clientes según presencia en ventas y devoluciones.

Proporción de clientes según presencia en ventas y devoluciones




Figura 4. Proporción de clientes con ventas, devoluciones o ambos.

3. Limpieza de datos y tratamiento de incidencias

La limpieza se centró en garantizar comparabilidad entre ventas y devoluciones. Se eliminaron los registros sin CustomerID, se verificaron los signos económicos, se revisaron productos administrativos y se trataron clientes no comparables cuya evolución supera la compra registrada. Estos casos podrían deberse a ventas fuera del periodo analizado, errores documentales o devoluciones asociadas a facturas no presentes en el dataset de ventas limpio.

Se detectaron dos clientes con valor neto negativo o devoluciones superiores a la compra registrada. Para evitar distorsionar la segmentación, se excluyeron de la base de modelado. La decisión es metodológicamente correcta porque el objetivo es comparar comportamiento comercial dentro de una ventana temporal consistente.




Figura 5. Cientes con devolución superior a la compra registrada.




Figura 6. Tasas de devolución en clientes extremos.

También se identificaron conceptos administrativos y productos asociados a gastos de envío. El caso más claro fue Next Day Carriage, que se excluye de ventas y devoluciones para evitar que importes logísticos alterarán el análisis de valor del cliente o producto.

4. Feature engineering a nivel cliente

Una vez depurados los datasets, se agregaron las transacciones a nivel cliente. Esta transformación convierte las líneas de factura en una tabla con una fila por CustomerID. El objetivo es disponer de variables representativas de valor, frecuencia, variedad, devoluciones y rentabilidad neta.

- GrossRevenue: importe bruto comprado por el cliente.
- ReturnAmount: importe total devuelto.
- NetRevenue: ingresos netos tras descontar devoluciones.
- PurchaseFrequency y ReturnFrequency: frecuencia de compra y devolución.
- ReturnRate: proporción económica devuelta sobre la compra.
- ReturnFrequencyRatio: relación entre frecuencia de devolución y frecuencia de compra.
- NetAverageOrderValue: ticket medio neto.
- UniqueProductsPurchased y UniqueProductsReturned: variedad de productos comprados y devueltos.
- HasReturns: indicador binario de presencia de devoluciones.

Tras la reconstrucción final se obtuvo un dataset de 4.331 clientes válidos para modelado y 25 variables. Los clientes con NetRevenue negativo, ReturnRate superior a 1 o QuantityReturnRate superior a 1 fueron eliminados para garantizar consistencia del modelo.

5. Exploración de variables, correlaciones y transformaciones

La matriz de correlación inicial mostró pares de variables altamente redundantes. Se detectaron correlaciones superiores a 0,85 entre GrossRevenue y NetRevenue, GrossRevenue y NetQuantity, TotalQuantityPurchased y NetQuantity, AverageOrderValue y NetAverageOrderValue, y QuantityReturnRate y ReturnRate. Para evitar multicolinealidad y variables duplicadas, se seleccionó una base reducida de variables de clustering.



Figura 7. Matriz de correlación de variables numéricas candidatas.




Figura 8. Número de pares detectados según umbral de correlación.

La selección final de variables preliminares para clustering fue: NetRevenue, NetAverageOrderValue, PurchaseFrequency, UniqueProductsPurchased, ReturnRate y ReturnFrequencyRatio. Se descartó HasReturns como variable principal para reducir redundancia con ReturnFrequencyRatio y evitar que el modelo separase clientes únicamente por la existencia binaria de devoluciones.




Figura 9. Correlación de variables preliminares para clustering.

El análisis de distribuciones mostró asimetrías elevadas en las variables económicas y de frecuencia. Por este motivo se aplicó transformación $\log_{1p}$ antes del escalado. La transformación redujo de forma notable la asimetría en NetRevenue, NetAverageOrderValue y UniqueProductsPurchased, permitiendo una entrada más estable para los modelos de clustering.





Figura 10. Distribuciones transformadas con $\log_{1p}$.

Figura 11. Boxplots transformados con $\log_{1p}$.



5.1 Reducción dimensional exploratoria

Se aplicaron PCA, t-SNE y UMAP como técnicas de visualización. PCA permitió interpretar la estructura global de varianza, mientras que t-SNE y UMAP facilitaron la lectura de agrupaciones locales y no lineales. Estas técnicas se usaron como visualización, no como criterio único de entrenamiento.




Figura 12. PCA 2D de clientes según comportamiento de devolución.




Figura 13. t-SNE 2D de estructura local de clientes.




Figura 14. UMAP 2D de proyección no lineal de clientes.

6. Entrenamiento y evaluación de modelos de clustering

Se entrenaron y compararon siete enfoques de clustering: K-Means, Gaussian Mixture Model, Agglomerative Clustering, DBSCAN, HDBSCAN, Spectral Clustering y BIRCH. Para cada modelo se calcularon métricas internas y criterios operativos: Silhouette, Calinski-Harabasz, Davies-Bouldin, Dunn Index, estabilidad ARI, número de clusters, equilibrio de tamaños y porcentaje de ruido cuando se aplica.

6.1 K-Means

K-Means fue evaluado para distintos valores de K. Aunque varias métricas aisladas sugieren configuraciones alternativas, K=4 ofreció el mejor equilibrio entre interpretabilidad, estabilidad y utilidad comercial. La configuración K=4 produjo segmentos diferenciados y accionables.




Figura 15. Comparación de métricas normalizadas para K-Means.




Figura 16. Evaluación individual de métricas K-Means.




Figura 17. Tamaño de clusters candidatos en K-Means.




Figura 18. Perfil relativo de clusters K-Means K=4.




Figura 19. Visualización PCA 2D de K-Means K=4.




Figura 20. Visualización t-SNE 2D de K-Means K=4.




Figura 21. Visualización UMAP 2D de K-Means K=4.

6.2 Modelos alternativos

Gaussian Mixture Model con 3 componentes generó una segmentación estable y probabilística, aunque menos granular que K-Means. Agglomerative con K=4 fue competitivo y visualmente coherente, pero su estabilidad fue inferior. DBSCAN y HDBSCAN aportaron valor como detectores de ruido y outliers, pero no como modelos principales de segmentación. Spectral y BIRCH generaron segmentaciones demasiado generales o desequilibradas.




Figura 22. Comparación de métricas normalizadas en Gaussian Mixture Model.




Figura 23. PCA 2D del modelo GMM candidato.




Figura 24. Comparación de métricas normalizadas en Agglomerative Clustering.




Figura 25. PCA 2D del modelo Agglomerative candidato.




Figura 26. Gráfico k-distance para DBSCAN.




Figura 27. Porcentaje de ruido según eps y min_samples en DBSCAN.




Figura 28. PCA 2D del modelo DBSCAN candidato.




Figura 29. Número de clusters según parámetros HDBSCAN.




Figura 30. Porcentaje de ruido según parámetros HDBSCAN.




Figura 31. PCA 2D del modelo HDBSCAN candidato.




Figura 32. Comparación de métricas normalizadas en Spectral Clustering.




Figura 33. PCA 2D del modelo Spectral candidato.




Figura 34. Top configuraciones BIRCH por métricas normalizadas.




Figura 35. PCA 2D del modelo BIRCH candidato.

7. Selección del modelo final y segmentos de clientes

La comparativa final sitúa a K-Means como el modelo más adecuado, con un score final ajustado de 0,62. DBSCAN aparece muy cerca con 0,61, pero su salida no es útil como segmentación comercial porque concentra casi todos los clientes en un único cluster y separa solo ruido o grupos mínimos. Por tanto, DBSCAN queda como técnica complementaria para outliers, no como modelo final.




Figura 36. Ranking final ajustado de modelos de clustering.




Figura 37. Comparativa normalizada de modelos de clustering.




Figura 38. Comparacion Silhouette vs Davies-Bouldin.




Figura 39. Comparativa operativa de ruido y equilibrio.

Tabla 1. Resumen de segmentos finales K-Means K=4.

Cluster	Segmento	Cientes	%	NetRevenue medio	Frecuencia	Prod. únicos	ReturnRate	ReturnFreqRatio
0	Cientes estándar de bajo valor	2.212	51,07%	405,97	1,68	25,30	0,00	0,01
1	Cientes con alta fricción por devoluciones	35	0,81%	184,35	1,94	19,57	0,69	0,97
2	Cientes de alto valor y alta actividad	1.543	35,63%	4.463,03	8,60	121,71	0,01	0,15
3	Cientes de valor medio con devoluciones	541	12,49%	882,53	2,39	39,87	0,07	0,79




Figura 40. Tamaño de segmentos finales K-Means K=4.




Figura 41. Perfil relativo de segmentos finales.




Figura 42. PCA 2D de la segmentación final.




Figura 43. t-SNE 2D de la segmentación final.




Figura 44. UMAP 2D de la segmentación final.

El segmento de clientes estándar de bajo valor agrupa la mayoría de la base. Tiene bajo valor neto, baja frecuencia y casi ausencia de devoluciones. El segmento de alta fricción por devoluciones es pequeño, pero muestra una tasa de devolución muy elevada y debe tratarse con cautela. El segmento de alto valor y alta actividad es el más estratégico, porque concentra el mayor valor neto y mantiene devoluciones proporcionalmente bajas. El segmento de valor medio con devoluciones presenta un valor moderado y una fricción comercial relevante que puede corregirse con acciones de producto, información y experiencia de compra.

8. Estrategias de marketing por segmento

La segmentación permite orientar estrategias diferenciadas según valor neto y fricción por devoluciones. Desde una perspectiva de marketing digital y neuromarketing, no se deben activar las mismas acciones para clientes rentables sin devoluciones que para clientes con alta tasa de devolución.

Tabla 2. Estrategias de marketing por segmento de cliente.

Segmento	Objetivo	Acciones	Indicador esperado
Clientes estándar de bajo valor	Reactivación y aumento de recurrencia	Email automatizado, recomendaciones simples, bundles de entrada, descuentos moderados de bajo coste.	Aumentar segunda compra y frecuencia sin elevar devoluciones.
Clientes con alta fricción por devoluciones	Control y diagnóstico	No incentivar agresivamente. Revisar productos comprados, mensajes de expectativa, política de devolución y posibles incidencias.	Reducir devoluciones y evitar erosión de margen.
Clientes de alto valor y alta actividad	Fidelización y retención premium	Programas VIP, early access, recomendaciones personalizadas, cross-selling, bundles de alto valor y trato prioritario.	Proteger el valor neto y aumentar CLV.
Clientes de valor medio con devoluciones	Optimizar experiencia y reducir incertidumbre	Mejorar fichas, guías de uso, comparativas, mensajes postcompra y recomendaciones más precisas.	Mantener valor comercial reduciendo fricción.

9. Análisis de productos devueltos

La última fase analiza las devoluciones desde la perspectiva del producto. Se agregaron ventas y devoluciones por StockCode y Description, calculando importe vendido, cantidad vendida, clientes compradores, facturas, importe devuelto, cantidad devuelta, clientes con devolución y tasas de devolución por importe, cantidad, facturas y clientes.

Se analizaron 3.658 productos vendidos. De ellos, 1.816 registraron al menos una devolución, lo que representa el 49,64% del catálogo vendido. Sin embargo, la tasa global de devolución fue moderada: 2,26% por importe y 1,89% por cantidad. Esto indica que el problema no está extendido en todo el catálogo, sino concentrado en productos concretos.

Aplicando un filtro de fiabilidad mínimo y una tasa de devolución por importe igual o superior al 15%, se identificaron 84 productos críticos. Estos productos requieren análisis individuales antes de promocionarlos, retirarlos o modificar su ficha comercial.




Figura 45. Top productos por importe total devuelto.




Figura 46. Top productos fiables por tasa de devolución en importe.




Figura 47. Comparativa de ventas o devoluciones en productos con mayor importe devuelto.




Figura 48. Relación entre volumen vendido y tasa de devolución por producto.




Figura 49. PCA 2D de productos según ventas y devoluciones.

El PCA de productos explica el 84,20% de la variabilidad total con dos componentes. PC1 se relaciona principalmente con volumen comercial y facturación. PC2 se asocia con tasas de devolución, por lo que permite separar productos con devoluciones proporcionalmente elevadas aunque no tengan el mayor volumen de ventas.

Tabla 3. Productos prioritarios por devolución e interpretación comercial.

Producto	Importe devuelto	Tasa aprox.	Interpretación
REGENCY CAKESTAND 3 TIER (soporte para tartas Regency de 3 niveles)	8.387,55	6%	Mayor importe devuelto, pero tasa moderada por alto volumen de ventas.
WHITE HANGING HEART T-LIGHT HOLDER (portavelas colgante blanco con forma de corazón)	6.588,90	7%	Alto volumen de ventas y devoluciones. Revisar embalaje y expectativas visuales.
FAIRY CAKE FLANNEL ASSORTED COLOUR (toallita/pastel decorativo de franela en colores surtidos)	6.553,62	38%	Alta tasa e impacto. Posible problema de surtido, lote o compras mayoristas.
PANTRY CHOPPING BOARD (tabla de cortar estilo despensa)	4.803,06	84%	Producto muy crítico por tasa e impacto económico.
WOODEN BOX ADVENT CALENDAR (calendario de adviento en caja de madera)	135,20	151%	Anomalía documental: devoluciones superiores a ventas registradas.
SET OF 3 BABUSHKA STACKING TINS (set de 3 latas apilables Babushka)	1.258,05	95%	Tasa casi total de devolución. Requiere revisión de producto y proveedor.
TEA TIME PARTY BUNTING (guirnalda decorativa Tea Time)	3.692,95	35%	Alta devolución en unidades e impacto relevante.
CINDERELLA CHANDELIER (lámpara o adorno tipo candelabro Cinderella)	1.114,05	35%	Varios clientes afectados. Revisar fragilidad y expectativas.

10. Estrategia de marketing basada en productos con devolución

La estrategia sobre productos devueltos debe diferenciar entre productos con alto impacto económico, productos con tasa de devolución anómala y productos con posible inconsistencia documental. No todos los productos devueltos deben retirarse ni todos deben promocionarse. La decisión debe depender de la tasa, el importe, el número de clientes afectados y el valor comercial del producto.

10.1 Clasificación operativa de productos devueltos

Tabla 4. Estrategia de marketing basada en productos devueltos.

Tipo de producto	Ejemplos	Acción de marketing/negocio	Objetivo
Alto impacto económico, tasa moderada	REGENCY CAKESTAND 3 TIER, WHITE HANGING HEART T-LIGHT HOLDER	Mantener en catálogo, revisar embalaje, fotos, medidas, materiales y calidad logística.	Reducir coste de devolución sin perder ventas.
Alta tasa e impacto relevante	PANTRY CHOPPING BOARD, FAIRY CAKE FLANNEL ASSORTED COLOUR, TEA TIME PARTY BUNTING	Pausar promociones agresivas, revisar ficha, proveedor, lote, fotografías, expectativas y mensajes de compra.	Reducir devolución estructural.
Alta tasa con baja muestra	WOODEN BOX ADVENT CALENDAR, GOLDIE LOOKING MIRROR, BLACK DIAMANTE EXPANDABLE RING	Auditar facturas y periodo; no concluir problema estructural sin revisar ventas históricas.	Evitar decisiones basadas en pocos casos.
Muchos clientes con devolución y tasa baja	JAM MAKING SET WITH JARS, SET OF 3 CAKE TINS PANTRY DESIGN	Seguimiento operativo normal; revisar embalaje si hay fragilidad.	Mantener ventas con control de experiencia.
Productos decorativos, frágiles o personalizados	Chandeliers, mirrors, holders, doorsigns, tins	Incluir medidas exactas, materiales, fotos reales, advertencias de color/tamaño y guía de uso.	Reducir expectativa no cumplida.

10.2 Acciones recomendadas

- No impulsar campañas de paid media ni email masivo sobre productos con tasa de devolución superior al 15% hasta revisar causa.
- Actualizar fichas de producto con fotografías reales, dimensiones, materiales, uso esperado y advertencias cuando haya colores surtidos o variaciones.
- Crear mensajes postcompra para productos frágiles: instrucciones de manipulación, comprobación al recibir y canal rápido de incidencia.
- Separar devoluciones por clientes mayoristas y clientes minoristas para evitar atribuir a producto lo que puede ser una devolución por volumen.
- Cruzar productos críticos con segmentos de cliente. Si un producto crítico aparece en clientes de alto valor, la prioridad de corrección aumenta.
- Aplicar promociones solo a productos con alto volumen, tasa baja y margen suficiente; evitar descuentos en productos con alta devolución y bajo valor neto.
- Crear un dashboard de seguimiento mensual con ReturnAmountRate, ReturnQuantityRate, ReturnCustomerRate y NetProductRevenue por producto.

Desde una perspectiva de neuromarketing, muchos problemas de devolución pueden originarse por desajuste entre expectativa y experiencia real. La solución no es sólo logística: también debe mejorar la comunicación visual y textual del producto. Cuanto más clara sea la representación del producto antes de la compra, menor será la probabilidad de devolución por decepción o interpretación incorrecta.

10.3 Solución propuesta por prioridad

Prioridad 1: revisar productos con alta tasa e impacto económico, especialmente Pantry Chopping Board, Fairy Cake Flannel Assorted Colour, Tea Time Party Bunting y Set of 3 Babushka Stacking Tins. Prioridad 2: auditar productos con devoluciones superiores a ventas registradas, como Wooden Box Advent Calendar, antes de tratarlos como problema comercial. Prioridad 3: optimizar productos de alto volumen y tasa moderada, como Regency Cakestand 3 Tier y White Hanging Heart T-Light Holder, porque pequeñas mejoras pueden reducir mucho importe devuelto total.

11. Conclusiones finales

La integración de ventas y devoluciones ha permitido construir una segmentación más realista que la basada solo en ingresos brutos. El valor neto permite identificar clientes realmente rentables, clientes con fricción por devoluciones y productos que pueden deteriorar la experiencia o el margen.

El modelo final seleccionado es K-Means con $K=4$. Esta elección se justifica por su equilibrio entre métricas, estabilidad, ausencia de ruido, granularidad comercial e interpretabilidad. Los segmentos finales permiten activar estrategias diferenciadas de reactivación, fidelización, control de devoluciones y optimización de experiencia.

El análisis de productos muestra que la tasa global de devolución es baja, pero existen 84 productos críticos. El problema no afecta a todo el catálogo, sino a productos específicos que deben revisarse por impacto económico, tasa de devolución o posible inconsistencia documental.

La aportación principal de esta fase es que une analítica de clientes y analítica de producto. Esto permite actuar sobre dos dimensiones: mejorar la rentabilidad por cliente y reducir las causas potenciales de devolución en productos concretos. La propuesta final combina segmentación, marketing personalizado y mejora operativa de producto.

Como mejora futura, se recomienda incorporar una variable explícita de motivo de devolución, costos logísticos, margen por producto y datos de campañas de marketing. Con estas variables se podría avanzar hacia un modelo predictivo de riesgo de devolución y valor de cliente ajustado por margen.