

MP6: Proyecto de IA y Big Data - Entrega Intermedia 1

Proyecto de Regresión: Predicción de Ventas en E-Commerce UK | Grupo E1: Adrian Sanz Llamas, Ioan Mark Bota, Juan Ramon Almiron Lopez, Mario Martin Sanchez | Master en IA y Big Data - LinkiaFP | Curso 2025/2026

Índice

1.	Introducción y contexto del proyecto
2.	Descripción del dataset
3.	Análisis exploratorio de los datos (EDA)
3.1	Exploración inicial y estadísticas descriptivas
3.2	Análisis de distribución temporal
3.3	Análisis geográfico
3.4	Detección de valores nulos y outliers
4.	Limpieza y transformación de datos
4.1	Eliminación de duplicados y pares de corrección
4.2	Tratamiento de anomalías y datos erróneos
4.3	Separación en datasets de ventas y devoluciones
4.4	Creación de la variable objetivo: ventas diarias

5.	Feature Engineering
5.1	Breve explicación e importancia
5.2	Categorías
5.3	Análisis de correlación
6.	Modelos de regresión entrenados
6.1	Random Forest Regressor
6.2	Prophet (Meta)
6.3	Regresión Multilineal, Regresión Polinómica (2º Grado), Árbol de Decisión y XGBoost
7.	Resultados y evaluación - Dataset de Ventas
7.1	Resultados sobre el test completo (27 días)
7.2	Hallazgo crítico: el outlier del 14 de noviembre
7.3	Análisis forense del pedido mayorista
7.4	Resultados sobre el test corregido (26 días)
8.	Resultados y evaluación - Dataset de Devoluciones
8.1	Random Forest
8.2	Prophet
8.3	Otros Modelos

8.4	Tabla Resultados Métricas - Dataset Devoluciones
8.5	Evaluación de los resultados y Conclusiones Dataset Devoluciones
9.	Flujo de Caja Neto
9.1	Random Forest
9.2	Prophet
9.3	Otros Modelos
9.4	Tabla Resultados Métricas - Dataset Flujo Caja Neto
9.5	Evaluación de los resultados y Conclusiones Dataset Devoluciones
10.	Conclusiones y líneas de mejora
10.1	Decisiones de las metodologías tomadas
10.2	Líneas de mejora para la memoria final

1. Introducción y contexto del proyecto

El proyecto simula un escenario real dentro del trabajo de un Data Scientist en una empresa de retail de comercio electrónico. La predicción de ventas es uno de los problemas más clásicos y de mayor impacto en este sector: permite planificar el stock eficientemente, anticipar necesidades logísticas, optimizar campañas de marketing y controlar el flujo de caja.

Objetivo del proyecto de regresión

Predecir el valor total de ventas diarias (libras esterlinas) de un e-commerce británico para cada día entre el 9 de noviembre de 2011 y el 9 de diciembre de 2011, utilizando como histórico los datos entre el 1 de diciembre de 2010 y el 8 de noviembre de 2011.

El equipo ha adoptado un enfoque en el que además de predecir las ventas brutas, se ha construido un segundo modelo paralelo para la predicción de devoluciones, de modo que la predicción final de ventas netas se obtiene como la diferencia entre ambas predicciones. Esta decisión metodológica se justifica en la sección 4 y permite una estimación más precisa del beneficio real diario.

Para abordar el problema, el equipo ha seguido la metodología estándar de un proyecto de Data Science end-to-end: análisis exploratorio (EDA), limpieza y transformación, ingeniería de características (Feature Engineering), entrenamiento y comparativa de varios modelos de regresión, y evaluación rigurosa con las métricas MAE, RMSE y R2.

Para estructurar el desarrollo del proyecto, el trabajo se dividió en tareas y se repartió entre dos grupos de dos integrantes, siguiendo una metodología de trabajo basada en Kanban

Se estableció una división inicial del trabajo en dos bloques. El primer grupo se responsabilizó del análisis exploratorio de los datos (EDA), mientras que el segundo se centró en el estudio de los modelos, las métricas de evaluación y la selección del método más adecuado para la predicción.

La coordinación entre ambos grupos se mantuvo de forma continua mediante reuniones periódicas de seguimiento y una comunicación diaria a través de canales digitales, lo que permitió compartir avances, contrastar enfoques y alinear las decisiones metodológicas adoptadas durante el desarrollo del proyecto.

A partir de esta organización inicial, el desarrollo del proyecto se llevó a cabo de forma iterativa y coordinada. Mientras el grupo de análisis exploratorio realizaba limpieza de los datos, la generación de versiones específicas del dataset y la construcción del notebook maestro con todo el código para generar cada variante del dataset, el grupo de modelado realizaba la investigación, implementación y comparación de distintos enfoques de regresión aplicados a ventas y devoluciones.

Este trabajo paralelo permitió no solo acelerar el avance del proyecto, sino también revisar de forma conjunta las decisiones metodológicas más relevantes, como la definición de las variables temporales, el tratamiento de devoluciones, la incorporación de técnicas de feature engineering y la selección de métricas comunes para evaluar todos los modelos. De este modo, el proyecto se fue consolidando mediante una dinámica de validación continua, en la que los resultados obtenidos en cada fase servían para refinar tanto el preprocesado como la estrategia de modelado.

2. Descripción del dataset

El dataset utilizado es el "E-Commerce Data" disponible en Kaggle, creado por la Universidad de Irvine (UCI Machine Learning Repository). Es un conjunto de datos transaccionales de comercio electrónico procedente de una empresa minorista británica que contiene todas las transacciones realizadas entre el **1 de diciembre de 2010 y el 9 de diciembre de 2011** por una empresa británica de venta en línea de artículos de regalo. Algunos de sus clientes son mayoristas que compran para revender, lo que introduce un comportamiento de compra dual que resulta crítico en el análisis de resultados.

Contiene **541.909 registros** y 8 variables principales y se trata de un dataset de naturaleza transaccional, donde cada fila representa una línea de factura y no una venta agregada por día, cliente o producto, característica que condiciona el trabajo posterior, ya que exige procesos de limpieza, transformación y agregación antes de poder utilizar los datos en tareas de regresión o segmentación.

Presenta 25.900 facturas únicas, 4.070 códigos de producto distintos, 4.372 clientes identificados únicos y operaciones distribuidas en 38 países.

El periodo temporal cubierto va desde el 1 de diciembre de 2010 hasta el 9 de diciembre de 2011, por lo que se dispone de algo más de un año de histórico, aunque con la particularidad de que diciembre de 2011 está incompleto, lo que se ha tenido en cuenta en el análisis temporal y en la interpretación de resultados.

Midiendo la calidad de los datos se puede comprobar que tiene varias incidencias, existen **135.080 valores nulos en CustomerID**, lo que supone aproximadamente un **24,93 %** del

total, así como **1.454 nulos en Description**, además, se detectaron **5.268 duplicados exactos**, equivalentes al **0,97 % del dataset**, lo que hacía necesaria una depuración previa antes del modelado.

También se identificaron **9.288 líneas de cancelación y 10.624 cantidades negativas**, lo que evidencia que el conjunto no representa exclusivamente ventas positivas, sino también operaciones de devolución que debían tratarse de forma específica. Esta circunstancia fue relevante a la hora de separar los datasets para orientarlos a ventas brutas, devoluciones y ventas netas.

Por último, el dataset presenta un **fuerte sesgo geográfico hacia Reino Unido**, que concentra **495.478 registros**, es decir, aproximadamente el **91,43 % del total** de filas, por lo que cualquier generalización con el resto de países debe analizarse.

Tabla de variables.

Columna	Tipo	Descripción
Invoice No	Texto	Número de factura. Si comienza por C, indica devolución
StockCode	Texto	Código del producto. Identificador único de cada artículo.
Description	Texto	Descripción del producto. Nombre del artículo vendido.
Quantity	Entero	Unidades por transacción. Valores negativos = devoluciones.
InvoiceDate	Fecha/Hora	Fecha y hora exacta de la transacción (resolución al minuto).
UnitPrice	Decimal	Precio unitario del producto en libras esterlinas.
CustomerID	Decimal	Identificador del cliente. Nulo en el 24,9% de los registros.
Country	Texto	País del cliente. Reino Unido = 91,7% del total.

Descripción de las columnas del dataset original.

Magnitud	Dataset original	Dataset ventas	Dataset devoluciones	Dataset Clustering
Total de registros	541.909	522.010	8.108	391.150
Países presentes	38	38	36	38
Peso Reino Unido	91,7%	91,6%	85,0%	91,7%
CustomerID nulos	24,9%	Conservados	Conservados	Sin Nulos
TotalPrice medio	15,31 GBP	19,09 GBP	-24,11 GBP	19.09 GBP

Estadísticas generales de los cuatro datasets del proyecto.

3. Análisis exploratorio de los datos (EDA)


El análisis exploratorio de los datos constituye la primera fase del proyecto y tiene como objetivo comprender la estructura, distribución y calidad del conjunto de datos antes de aplicar procesos de limpieza, transformación o modelado. Para ello, se utilizaron principalmente las librerías Pandas para el cálculo de estadísticas descriptivas y Matplotlib y Seaborn para la representación gráfica de los principales patrones observados.

A través de esta fase se analizaron la distribución de las variables numéricas, el comportamiento temporal de las transacciones, la presencia de valores nulos, la concentración geográfica del negocio y la existencia de valores extremos. Este análisis permitió identificar patrones relevantes del dataset y orientar las decisiones metodológicas adoptadas en las fases posteriores del proyecto.

TotalPrice, calculada como **Quantity × UnitPrice**, se utilizó como variable económica base para posteriores agregaciones y análisis.

3.1. Exploración inicial y estadísticas descriptivas

La exploración inicial confirmó que el dataset tenía una estructura transaccional, en la que cada fila representaba una línea de factura. Las variables numéricas más relevantes para esta fase fueron Quantity, UnitPrice, TotalPrice e InvoiceHour, ya que permitían caracterizar el volumen de compra, el precio unitario, el importe económico por línea y el patrón horario de las transacciones.



Las variables Quantity, UnitPrice y TotalPrice presentan distribuciones asimétricas, con una fuerte concentración de valores bajos y una cola larga hacia valores elevados. En Quantity, la diferencia entre la media (10,32) y la mediana (4) indica que predominan las compras de pequeño volumen, aunque existen operaciones puntuales de gran tamaño. En UnitPrice ocurre algo similar: la media (3,27 GBP) supera a la mediana (2,08 GBP), lo que refleja que la mayoría de los productos tienen precios bajos, aunque conviven con algunos importes unitarios mucho más elevados. Por su parte, TotalPrice, calculada como $\text{Quantity} \times \text{UnitPrice}$, muestra una dispersión aún mayor, con una desviación típica de 84,60 GBP y un máximo de 38.970 GBP.

En cuanto a InvoiceHour, todas las transacciones se concentran entre las 6:00 y las 20:00 horas, con una media situada en torno a las 13:08, lo que sugiere una operativa alineada con el horario laboral.

En conjunto, estas primeras estadísticas permitieron detectar desde el inicio la presencia de asimetrías, alta dispersión y valores extremos, aspectos que resultarían determinantes en las fases posteriores de depuración y modelado.

Estadístico	Quantity	UnitPrice	CustomerID	TotalPrice	InvoiceHour
Count	522.010	522.010	390.600	522.010	522.010
Media	10,32	3,27	15.295,82	19,09	13,08
Desv. típica	37,81	4,38	1.710,32	84,60	2,44
Mínimo	1	0,001	12.347	0,001	6
Mediana (P50)	4	2,08	15.159	9,90	13
Máximo	4.800	649,50	18.287	38.970	20

Estadísticas descriptivas de las variables numéricas del dataset de ventas.

3.2. Análisis de distribución temporal


La distribución temporal de las transacciones muestra un patrón estacional claro. La mayor actividad se concentra en el tramo final del año, especialmente en octubre, noviembre y diciembre que parece responder a una precampaña navideña.

Se descartó atribuir este comportamiento exclusivamente al Black Friday, dado que, aunque esta práctica ya había sido introducida en Reino Unido, durante el periodo analizado aún no presentaba el grado de implantación y consolidación observado en años posteriores.

Por el contrario, enero y febrero presentan un menor volumen de operaciones, en coherencia con la finalización de la campaña navideña.

El análisis por día de la semana nos muestra que los domingos no se registran transacciones y los sábados presentan una actividad muy reducida. Esto nos hizo pensar en un comportamiento compatible con el componente de negocio B2B, ya que las transacciones se centran en la semana laboral.

Este patrón temporal resultó especialmente relevante para el proyecto, ya que indicaba que el día de la semana podía tener un peso predictivo importante en los modelos de regresión




Distribución de transacciones por mes. Noviembre concentra el mayor volumen, coherente con la estacionalidad navideña del e-commerce de regalos.


3.3. Análisis geográfico y de nulos

El dataset presenta una **fuerte concentración en Reino Unido**, que representa aproximadamente el **91,7 % de las transacciones**. Esto condiciona el análisis global, ya que los patrones observados reflejan sobre todo el comportamiento del mercado británico.

En cuanto a los valores faltantes, la única columna con **nulos relevantes es CustomerID**, con un **24,9 %** de registros sin identificar (135.080 filas). Dado que esta variable actúa como identificador y no como predictor directo en los modelos de regresión, se optó por conservar estos registros en los datasets orientados a predicción. No obstante, este aspecto sí resultó determinante en la construcción del dataset de clustering, donde fue necesario trabajar únicamente con clientes identificados.



Distribución geográfica. Izquierda: peso del Reino Unido frente al resto. Derecha: top 8 países excluyendo el Reino Unido.




Porcentaje de valores nulos por columna. Solo CustomerID presenta nulos significativos (24,9%).

3.4. Análisis de outliers

Se realizó el análisis de valores extremos mediante el criterio IQR (rango intercuartílico), que reveló la presencia de outliers en Quantity, UnitPrice y TotalPrice. Estos valores se analizaron y se corroboró que, en gran medida, eran por operaciones de gran volumen o importe elevado, coherentes con la actividad real del negocio y no necesariamente atribuibles a errores de registro.

Por este motivo, no se optó por eliminarlos de forma indiscriminada en la fase inicial, ya que forman parte del comportamiento real del dataset. Su impacto sí se tuvo en cuenta en la fase de modelado, especialmente ante la presencia de determinados picos muy pronunciados en el periodo de test, como el observado el 14 de noviembre de 2011, que requirió una consideración específica en el análisis de resultados (Sección)



Izquierda: distribución de TotalPrice excluyendo el P99. Derecha: boxplot hasta 500 GBP mostrando la concentración de valores bajos y la presencia de outliers extremos.

Variable	Q1	Q3	Lim. sup. IQR	Outliers aprox.	% total
Quantity	1	12	28,50	~52.000	~10%
UnitPrice	1,25	4,13	8,75	~31.000	~6%
TotalPrice	3,90	17,70	38,85	~51.000	~10%

Análisis de outliers por variable mediante criterio IQR.

4. Limpieza y transformación de datos

La fase de limpieza es la más crítica de cualquier proyecto. Un modelo entrenado sobre datos sucios producirá predicciones poco fiables independientemente de su sofisticación. El proceso de limpieza ha seguido una secuencia estructurada de siete pasos aplicados en el orden correcto.

4.1. Eliminación de duplicados y pares de corrección

Se han eliminado filas completamente duplicadas (errores informáticos o humanos en el registro). Adicionalmente, se han detectado y eliminado pares de corrección o revisión dentro de una ventana temporal de 12 horas: transacciones positivas seguidas de su negativa correspondiente realizadas en la misma sesión, que representan correcciones de la propia empresa y no devoluciones reales del cliente.

4.2. Tratamiento de anomalías y datos erróneos

Se han identificado filas anómalas mediante la combinación de cuatro condiciones: UnitPrice igual a cero, Quantity menor o igual a cero, CustomerID nulo y Description nula. Se han evaluado tres criterios alternativos de filtrado y se ha seleccionado el Criterio 3 por su mejor equilibrio entre conservación de datos válidos y eliminación de registros sin valor.

Opción	Criterio	Estado
1	(UnitPrice=0 AND Quantity menor/igual a 0) OR (CustomerID nulo AND Description nula)	Evaluada
2	UnitPrice=0 AND Quantity menor/igual a 0 AND CustomerID nulo AND Description nula	Evaluada
3 ELEGIDA	UnitPrice=0 OR (Quantity menor/igual a 0 AND CustomerID nulo AND Description nula)	SELECCIONADA

Criterios de filtrado de anomalías evaluados. Se ha seleccionado la opción 3.

Adicionalmente, se han eliminado líneas cuya descripción corresponde a conceptos no comerciales: *POSTAGE, DOTCOM POSTAGE, MANUAL, CARRIAGE, AMAZON FEE, ADJUST BAD DEBT, BANK CHARGES, DISCOUNT, SAMPLES* y *CRUK COMMISSION*. Estos registros distorsionarían el cálculo de ingresos diarios al incluir conceptos que no son ventas de producto real.

4.3. Separación en datasets de ventas y devoluciones

La separación del dataset limpio en dos subconjuntos independientes es la decisión metodológica más importante del proyecto. Los patrones de devoluciones son estadísticamente distintos de los de ventas: son menos frecuentes, más aleatorios temporalmente y de menor volumen. Mezclar ambos en un único modelo confundiría al algoritmo, que intentaría aprender dos comportamientos opuestos simultáneamente.

- **Dataset de ventas:** todos los pedidos cuyo **InvoiceNo NO comienza por C** y cuya Quantity es positiva. Representa el flujo ordinario de ingresos.
- **Dataset de devoluciones:** todos los pedidos cuyo **InvoiceNo comienza por C** o cuya **Quantity es negativa**. Representa el flujo de reintegros al cliente.

La predicción final de ventas netas se calcula como: **Ventas netas = Ventas brutas predichas - Devoluciones predichas**. Las devoluciones representan solo el 1,1% de las ventas brutas en el periodo de test.

4.4. Creación de la variable objetivo: ventas diarias

La variable objetivo no existe directamente en el dataset original. Hay que transformar las miles de transacciones individuales en una única cifra por día: el total de ingresos de ese día. Se aplica una operación de agregación (groupby sobre InvoiceDate, sumando TotalPrice), que convierte el dataset en una serie temporal. Este paso, implementado en la función *preprocess_for_all_models*, cambia la naturaleza del problema: de predecir una transacción individual a predecir el comportamiento agregado de un día completo.

5. Feature Engineering

5.1. Breve explicación e importancia

La ingeniería de características (*Feature Engineering*) es el proceso mediante el cual se transforman datos brutos en variables que permiten a los modelos de aprendizaje automático realizar predicciones más precisas. Se considera una de las etapas más críticas del ciclo de vida de un proyecto de ciencia de datos, dado que un modelo sencillo entrenado con características de calidad suele superar a modelos más complejos entrenados con datos mediocres.

5.2. Categorías

Este proceso es iterativo y depende en gran medida del conocimiento del dominio del problema. Se estructura en las siguientes categorías:

5.2.1. Creación de Características o Features

Esta etapa consiste en generar nuevas variables a partir de la combinación o extracción de información contenida en los datos originales.

El dataset **E-Commerce de UK** presenta las siguientes columnas en su estado original:

- InvoiceNo
- StockCode
- Description
- Quantity
- InvoiceDate
- UnitPrice
- CustomerID
- Country

5.2.2. Variable Objetivo - DailytTotal

La primera feature creada fue la variable objetivo del modelo. La columna **DailyTotal** se obtiene mediante la agrupación por fecha de transacción (**suma de la columna TotalPrice creada en la fase de EDA**) , y representa el valor total de transacciones de esa jornada o día , en nuestro caso tanto para ventas como devoluciones.

Esta variable es la que el modelo deberá aprender a predecir.

5.2.3. Descomposición Temporal de la columna Original de InvoiceDate

La columna **InvoiceDate**, de tipo categórico, contiene información temporal de alto valor para un modelo orientado a la predicción de ventas diarias. Por ello, se decidió descomponerla en cuatro variables numéricas independientes:


- **InvoiceDay**
- **InvoiceMonth**
- **InvoiceYear**
- **InvoiceHour**

Esta descomposición permite al modelo capturar patrones estacionales, tendencias mensuales y comportamientos horarios que de otro modo permanecerían implícitos en una única columna de texto.

5.2.4. Variable DayOfWeek

Con el fin de incorporar el comportamiento semanal de las ventas, se evaluaron dos alternativas. La primera consistía en crear una variable binaria **IsWeekend** (0 = día laborable, 1 = fin de semana). Sin embargo, esta codificación introduce una **pérdida de granularidad** significativa: al reducir siete categorías a sólo dos, el modelo pierde la

capacidad de distinguir patrones específicos de cada día.



Los datos del propio dataset ilustran claramente este problema. Como se puede observar en el gráfico anterior, el jueves es el día con mayor volumen de transacciones (2.121), seguido del miércoles (1.586) y el martes (1.506). Esta concentración de actividad a mitad de semana quedaría completamente invisible para un modelo que solo distingue entre día laborable y fin de semana. Más revelador aún es el comportamiento dentro del propio fin de semana: el sábado registra 0 transacciones, mientras que el domingo acumula 395, una diferencia radical que un binario **IsWeekend** trataría como equivalente.

Por estas razones, se optó por crear la variable **DayOfWeek**, con valores numéricos del 0 (lunes) al 6 (domingo). Esta representación preserva la granularidad completa del ciclo semanal, permitiendo al modelo identificar patrones diferenciados por día que, como demuestran los datos, son marcados y relevantes para la predicción de ventas.


Variable	Justificación
InvoiceHour	Hora del día en el que se realizó la transacción, captura los patrones de actividad del día, permitiendo al modelo identificar franjas de mayor concentración de ventas.
InvoiceDay	Día del mes en el que se realiza la transacción, permite al modelo detectar patrones dentro del mes, como picos de ventas al principio o al fin de mes.

InvoiceMonth	Mes del año en el que se realiza la transacion(0-11), permite al modelo capturar la estacionalidad anual del negocio ,recogiendo por ejemplo fenómenos como periodos navideños o campañas estacionales.
DayOfWeek	Día de la semana codificado 0 (lunes) y 6 (domingo).Captura el ciclo semanal de la actividad comercial,permitiendo al modelo distinguir el comportamiento diferenciado de cada jornada diaria.
IsWeekend	Variable binaria que indica si la transacción se realizó un día laborable o no, esta complementa a dayofweek ofreciendo más contexto del comportamiento en festivos.

Variables o features creadas mediante Feature Engineering.

5.2.5. Variable geográfica Country

Se creó la variable binaria **isUK** (0 = transacción internacional, 1 = transacción nacional) para que el modelo supiera si cada transacción era nacional o internacional.



Distribución de transacciones dentro y fuera de United Kingdom.

Como se ve en la Figura 7, el dataset está muy desequilibrado geográficamente: 6.891 transacciones son de dentro del Reino Unido frente a solo 1.217 internacionales, lo que supone aproximadamente un **85% nacional** vs un **15% internacional**.

Este desequilibrio introduce un **sesgo geográfico** en el modelo: al haber visto predominantemente transacciones nacionales durante el entrenamiento, tenderá a predecir siguiendo patrones de comportamiento de compra de UK, pudiendo generalizar mal ante transacciones internacionales.

Se valoraron distintas alternativas para abordar este problema, entre ellas eliminar las transacciones internacionales del dataset. La ventaja de esta opción es que eliminaría completamente el sesgo geográfico, pero la desventaja es que el modelo perdería toda capacidad de predecir ventas fuera del Reino Unido, limitando la posibilidad de tomar decisiones frente al mercado internacional.

Finalmente se optó por mantener el dataset completo y documentar este sesgo como una **limitación conocida del modelo**, asumiendo que el foco principal del sistema de predicción es el mercado nacional.

5.2.6. Lag features y ventanas deslizantes

La predicción del valor total de ventas diarias no es un problema estático, el volumen económico registrado en una jornada determinada no es independiente de lo ocurrido en los días anteriores. Estos patrones de consumo presentan memoria, es decir, existe una dependencia temporal entre observaciones sucesivas que los modelos de aprendizaje automático convencionales no están diseñados por sí solos para capturarlos de forma nativa.

Si se entrena el modelo únicamente con las features o características estáticas descritas en apartados anteriores, como el **DayOfWeek**, **dayOfMonth** o **isUK**, se proporciona al modelo un contexto de cada jornada, pero sin información alguna sobre la trayectoria reciente de las ventas.

Para abordar esta limitación, utilizamos dos familias derivadas de las series temporales: **Lag Features y las Rolling Features**. El objetivo principal del uso de ambas es la misma, añadir o codificar el comportamiento pasado del negocio como señales de entrada a nuestros modelos, de forma que este pueda aprender no solo en un contexto de una jornada de ventas, sino cuál ha sido la evolución de ventas reciente en los días previos al día que se quiere predecir.

En el contexto del dataset de E-commerce de UK, es razonable pensar que las ventas de hoy tienen algo que ver con las de ayer, o las de la semana pasada, es decir, un buen día de ventas suele venir acompañado de otros, los efectos de una promoción no desaparecen

de golpe, y los ciclos semanales hacen que ciertos días se parezcan más entre sí de lo que aparecen a simple vista.

Las variables generadas en esta sección buscan trasladar esa intuición al modelo de forma explícita, dando acceso al historial reciente de ventas para que pueda aprender de él.

Variable	Justificación
sales_lag_1	Memoria a corto plazo: captura las ventas del día anterior, si ayer vendí mucho, hoy probablemente también.
sales_lag_7	Memoria semanal: captura las ventas de hace siete días, permitiendo al modelo comparar cada jornada semanal con su equivalente más reciente.
rolling_mean_7	Media semanal : captura la media de ventas de los últimos 7 días, esto suaviza la variabilidad diaria.
rolling_mean_30	Media mensual: captura la media de ventas de los últimos 30 días, representa la tendencia del negocio a medio plazo y el nivel general de actividad del último mes.

Features temporales Lag y ventanas deslizantes.

Además de los lag features individuales, se creó una variable de tendencia a corto plazo **trend_1_vs_7** como indicador de la dirección en la que están evolucionando las ventas. Esta variable se calcula como la diferencia entre el valor de ventas del día anterior (**sales_lag_1**) y el de hace siete días (**sales_lag_7**), capturando así si el negocio se encuentra en un momento ascendente o descendente respecto a la semana previa.

En un principio pensamos que añadir esta tendencia era redundante con **rolling_mean_7** ya que ofrece información similar, pero mientras **rolling_mean_7** informa del nivel medio de ventas reciente, la resta **sales_lag_1 - sales_lag_7** captura la dirección en la que se están moviendo. Por ejemplo si dos series semanales con trayectorias opuestas, una que sube de 100€ a 700€ y otra que baja de 700€ a 100€, comparten el mismo **rolling_mean_7** de 400€, pero devuelven +600€ y -600€ respectivamente al calcular la diferencia, indicando cómo hay una evolución descendente de ventas. Por eso ambas variables son complementarias y no redundantes.


Variable	Justificación
trend_1_vs_7	Captura la evolución de ventas de la última semana , mediante la diferencia de lag 1 y lag 7 , otorgando al modelo información sobre si el negocio se encuentra en un momento ascendente o descendente.

Feature de tendencia lag_1 vs lag_7.

5.3. Análisis de correlación

Con el objetivo de analizar la relación de las variables generadas frente a la variable objetivo, se realizaron dos análisis de correlación utilizando los coeficientes de Pearson y Spearman. Pearson mide la relación lineal entre variables, mientras que Spearman trabaja sobre el ranking de los valores, siendo más robusto ante la presencia de outliers.

Dado que el dataset tiene jornadas con transacciones anómalas que podrían distorsionar los resultados, se decidió usar ambos métodos para poder comparar. A continuación se incluyen los gráficos de Pearson y Spearman tanto para ventas como para devoluciones, usando Spearman como referencia principal.



Correlación Pearson Vs Spearman para ventas y devoluciones,

Podemos observar como las variables con más relación con el target son las features de tiempo junto con **Quantity** y **UnitPrice** , aunque podemos destacar cómo estas variables se muestran en diferentes órdenes , esto se debe a que Pearson calcula la correlación sobre los valores absolutos , por lo que los días con picos tienen más peso desproporcionado el resultado , mientras que spearman trabaja sobre el ranking de los valores , es decir si un día en concreto ha vendido mucho , ese se pondrá numero 1 en el ranking, esto refleja de forma más fiel la relación estructural con la variable objetivo.

Con la partición del dataset para ventas y devoluciones podemos observar como la feature de **UnitPrice** se muestra diferente , teniendo más correlación con la variable objetivo en el dataset de ventas que en el dataset de devoluciones que tiene un correlación más negativa.

5.4. Métricas de evaluación seleccionadas

Se han seleccionado tres métricas complementarias, descartando MSE por las razones indicadas en la tabla.

Métrica	Cálculo	Interpretación	Estado
MAE	$\text{Media}(\text{real} - \text{pred})$	Error medio en GBP. El más intuitivo para negocio: nos equivocamos X GBP al día de media.	Seleccionada
RMSE	$\text{Raíz}(\text{Media}((\text{real} - \text{pred})^2))$	Penaliza errores grandes. Si RMSE es muy superior a MAE, hay días críticos muy malos.	Seleccionada
R2	$1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}$	Mayor de 0 = mejor que la media. Menor de 0 = peor que la media. 1,0 = predicción perfecta.	Seleccionada
MSE	$\text{Media}((\text{real} - \text{pred})^2)$	Unidades al cuadrado (GBP^2). Imposible de interpretar en términos de negocio.	Descartada

Métricas de evaluación. MSE se descarta por su difícil interpretabilidad en unidades monetarias.

6. Modelos de regresión entrenados

El equipo ha entrenado y evaluado cinco algoritmos cubriendo un benchmark completo: desde los enfoques más simples hasta los más sofisticados. Para todos se ha usado la misma división temporal y las mismas métricas, garantizando una comparativa justa.

6.1. Random Forest Regressor

El Random Forest es un método de aprendizaje en conjunto que genera un ensamble compuesto por un grupo de árboles de decisión independientes y fusiona sus predicciones por medio de promedios. Cada árbol se entrena a partir de una muestra aleatoria del conjunto de datos (Bootstrap) y, en cada nodo de los árboles, solo se consideran un grupo aleatorio de variables (aleatoriedad de características).

Esta doble aleatoriedad asegura que los árboles sean diferentes entre sí, compensando su error individual pero también favoreciendo la generalización de los árboles. El Random Forest es un método razonablemente robusto ante valores atípicos y no requiere que las variables predictivas se encuentren normalizadas.

6.1.1. Hiperparámetros de Random Forest optimizados

Hiperparámetro	Rango probado	Mejor valor	Efecto
n_estimators	[100, 200, 300, 500]	300	Número de árboles. Más = mayor estabilidad.
max_depth	[5, 10, 15, 20]	20	Profundidad máxima del árbol.
min_samples_split	[5, 10, 15]	10	Mínimo de muestras para dividir un nodo.
min_samples_leaf	[2,4,8]	2	Mínimo de muestras en una hoja final.
max_features	[1.0, 'sqrt', 'log2']	1.0	Máximo de variables al tomar una decisión, para limitar overfitting.

Hiperparámetros de Random Forest optimizados con RandomizedSearchCV y TimeSeriesSplit (40 de 144 combinaciones muestreadas).

El equipo ha realizado comparativas entre **GridSearchCV** (una búsqueda exhaustiva de hasta 432 combinaciones) y la **RandomizedSearchCV** (una búsqueda aleatorizada de hasta 40 combinaciones). Los resultados indican que RandomizedSearchCV es aproximadamente 10 veces más rápido, manteniendo resultados similares, por lo que se ha decidido escoger esta estrategia para el modelo final.

6.1.2.PROCESO COMPLETO DEL ENTRENAMIENTO

1. Preparación de los Datos e Ingeniería de Características (Feature Engineering)

Para la predicción de la facturación diaria, decidimos implementar un modelo Random Forest Regressor. Sin embargo, a diferencia de algoritmos nativos de series temporales (como ARIMA o Prophet), los modelos basados en árboles de decisión carecen de memoria temporal; es decir, procesan cada registro de forma aislada sin comprender la secuencialidad de los días.

Con el fin de proporcionar al algoritmo este "contexto temporal" se llevó a cabo un proceso exhaustivo de Feature Engineer. Tras este tratamiento, **dividimos los datos cronológicamente**, destinando **278 días para el entrenamiento**, **27 días para validación interna** y reservando los **últimos 27 días (del 9 de noviembre al 9 de diciembre) como conjunto de Test final** puro.

2. Validación Cruzada Temporal y Optimización Computacional

Dada nuestra experiencia previa y sabiendo que el riesgo más importante que presenta un modelo Random Forest consiste en que se produce sobreajuste (overfitting), evitamos el uso de la validación cruzada tradicional, pues en los casos de series temporales el uso de la validación cruzada tradicional puede provocar una fuga de datos (data leakage) al aprender del futuro para predecir el pasado.

¿Entonces cuál es la solución? Implementar un *TimeSeriesSplit* con 3 particiones, forzando así al modelo a aprender, y evaluarse, siempre hacia delante en el tiempo.

Para poder buscar los hiperparámetros óptimos y entrenar el modelo para su validación con el resto de los datos, nos vimos ante un espacio de 432 combinaciones. Por criterios de eficiencia y de aplicabilidad en un entorno real de negocio (*MLOps*), decidimos descartar la fuerza bruta del *GridSearchCV* en favor de un muestreo inteligente con *RandomizedSearchCV*.

Limitar la búsqueda a 40 iteraciones aleatorias nos permitió encontrar la configuración óptima en 58,21 segundos. El algoritmo aprendió en los siguientes parámetros:

- **n_estimators:** 300 (De esta forma aseguramos que el promediado es bastante robusto).
- **max_depth:** 20 (Permitiendo suficiente profundidad para aprender patrones, pero limitando el crecimiento ilimitado).
- **max_features:** 1.0 (Se usan las características completas tras comprobar que la descorrelación no mejoraba este set en particular).
- **min_samples_split:** 15 y **min_samples_leaf:** 2 (Fuerza el modelo a ser conservador y no elaborar reglas matemáticas quebrando patrones para datos aislados).

3. Cómo piensa el Random Forest

Finalmente, extrajimos la importancia matemática otorgada a cada variable predictora (Feature Importance). Como se observa en el gráfico generado:



Nos dimos cuenta de algo bastante claro: lo que más pesa no son las ventas del día anterior, sino el contexto general. Con bastante diferencia, la variable más importante es la media de los últimos 7 días (**rolling_mean_7**), y después vienen el día de la semana y el mes. Esto encaja bastante con lo que pensábamos al principio: en e-commerce, lo que manda es la tendencia semanal y los hábitos de compra según el calendario, más que lo que pasó justo ayer.

También vimos algo curioso al intentar reducir el ruido de los datos. Las ventas del día anterior (**sales_lag_1**) prácticamente no aportan nada al modelo. Es como si el algoritmo hubiera “aprendido” que el retail es muy variable y poco predecible a corto plazo, así que no se fía de un solo día. En lugar de eso, se apoya más en métricas más estables y suavizadas, como las medias móviles a más largo plazo o comparaciones de tendencia (**rolling_mean_30**, **trend_1_vs_7**), para no dejarse llevar por picos puntuales.

6.2. Prophet (Meta)

Prophet es una librería de predicción de series temporales de Meta (Facebook). Descompone la serie en cuatro componentes:

- tendencia $g(t)$,
- estacionalidad $s(t)$,
- efectos de eventos especiales $h(t)$
- ruido $e(t)$.

El equipo ha probado diferentes combinaciones en el modelo con distintas configuraciones de hiperparámetros como **changepoint_prior_scale** o **seasonality_mode** (**aditivo vs multiplicativo**) y seleccionando la mejor por menor MAE y RMSE y mayor R2.

A continuación se realiza una breve explicación de cada uno de los hiperparámetros utilizados para la configuración del modelo:

seasonality_mode: define cómo se combinan los patrones estacionales (como el aumento de ventas en Navidad) con la tendencia base.

- **additive:** Se usa cuando el efecto estacional es **constante** en términos absolutos. Ejemplo: si en Navidad siempre se venden 1,000€ más, sin importar si nuestra empresa ha crecido o no. Es el valor por defecto.
- **multiplicative:** Se usa cuando la estacionalidad **crece proporcionalmente** a la tendencia. Ejemplo: si en Navidad vendemos un 20% más; por tanto, si nuestra empresa crece, ese "pico" navideño también se hace más grande visualmente.

En el objetivo predicción ventas diarias: Se han probado las dos opciones, obteniendo mejores resultados con "aditive", probablemente porque solo disponemos ventas en el rango de un solo año 2010 a 2011, y con "multiplicative" el modelo no es capaz de captar ninguna tendencia de crecimiento, con lo que las predicciones son menos precisas.

changepoint_prior_scale: Controla la flexibilidad de la tendencia. Determina cuánto puede "curvarse" la línea para adaptarse a cambios bruscos (como el inicio de una pandemia o un cambio de algoritmo en Google Ads).

- **Valores bajos (0.001 - 0.01):** Hacen que la tendencia sea muy **rígida** (casi una línea recta). Evita el *overfitting* (sobreajuste), pero puede ignorar cambios reales de dirección en el negocio.
- **Valores altos (0.1 - 0.5):** Hacen que la tendencia sea muy **flexible**. Se adapta rápido a los cambios, pero puede confundir ruido aleatorio con cambios de tendencia.
- **Valor por defecto: 0.05**

En el objetivo predicción ventas diarias: Se ha probado varios valores desde muy bajos a más altos, pero los mejores resultados se obtienen cuando se usan valores altos en este hiperparámetro, concretamente valor 0.1. Esto probablemente es debido a que la gráfica de datos reales tiene muchas curvas (subidas y bajadas) y tal como hemos explicado con valores altos hace que la tendencia del modelo sea más flexible y se adapte mejor a los cambios.

yearly_seasonality, weekly_seasonality, daily_seasonality: Activan o desactivan el análisis de ciclos temporales específicos.

- **True:** Prophet usa series de Fourier (fórmula matemática para descomponer cualquier señal o patrón complejo (como las ventas diarias) en una suma de ondas simples: senos y cosenos) para detectar el patrón.
- **False:** El modelo ignora ese ciclo.
- **auto:** Prophet decide según la cantidad de datos (necesita al menos 2 años para la anual).


En el objetivo predicción ventas diarias:

- yearly: Mejores resultados cuando se ha activado. Es crucial para e-commerce.
- weekly: Mejores resultados cuando se ha activado. Detecta ventas de fin de semana o entre semana.
- daily: Dado que el objetivo de son ventas diarias (facturación total del día) y en las fechas hemos quitado las horas y minutos, debe estar **desactivado** (False). Solo se usa True si tuviéramos datos por horas o minutos.

Por último comentar, que también se ha utilizado los “**regresores**” nativos de Prophet (función **add_regressor**) para añadir al modelo previamente a su entrenamiento, las variables temporales que se crearon en la sección de feature engineering (**month, day_of_week, is_weekend, etc**). Se realizaron entrenamientos sin añadir estos regresores y después añadiendo los progresivamente, obteniendo mejores resultados en las métricas de evaluación cuando se han añadido los regresores con las variables temporales al modelo.

Cómo piensa Prophet

Visualizamos la importancia matemática otorgada a cada variable predictora (Feature Importance). Como se observa en el gráfico generado:



6.3. Regresión Multilineal, Regresión Polinómica de segundo grado, Árbol de Decisión y XGBoost

La regresión lineal múltiple es el modelo más básico de todos estos. Lo que hace es intentar explicar una variable en función de varias variables de entrada, asumiendo que la relación entre ellas es lineal. Es sencilla, rápida y fácil de interpretar, aunque se puede quedar corta cuando las relaciones entre variables son más complejas.


La regresión polinómica de grado 2 es como una versión un poco más completa de la regresión lineal. En vez de quedarse solo con relaciones “rectas”, añade términos al cuadrado y combinaciones entre variables, lo que nos permite captar comportamientos no lineales. En nuestro caso, la usamos dentro de un pipeline que combina esas transformaciones con una regresión lineal.

El árbol de decisión funciona de una forma bastante intuitiva: va dividiendo los datos en grupos cada vez más pequeños según ciertas reglas, como si fuera un diagrama de decisiones. Esto hace que sea fácil de entender, pero también tiene el problema de que puede ajustarse demasiado a los datos (overfitting). Para controlarlo, ajustamos sus parámetros con técnicas como GridSearchCV, y lo usamos un poco como punto de referencia para comparar con modelos más complejos como Random Forest.

XGBoost (eXtreme Gradient Boosting) sigue otra lógica distinta: en lugar de crear muchos árboles independientes, los va construyendo uno detrás de otro. Cada nuevo árbol intenta corregir los errores que ha cometido el anterior. Es un proceso iterativo que suele dar muy buenos resultados, sobre todo en datos tabulares, por eso es tan popular en competiciones.

7. Resultados y evaluación - Dataset de Ventas


Esta sección presenta los resultados sobre el periodo de test (9 noviembre - 9 diciembre 2011). El periodo registra 1.512.326 GBP en ventas brutas, con media diaria de 56.012 GBP y variabilidad muy alta (desde 21.280 hasta 111.349 GBP el día más elevado).



Serie temporal completa de ventas diarias. Zona azul: entrenamiento (278 días). Zona verde: test (27 días). Punto rojo: pico del 14 de noviembre 2011.

7.1. Resultados sobre el test completo (27 días)

7.1.1 RANDOM FOREST



Cuando evaluamos el modelo en el conjunto de datos de test sin filtrar, encontramos un MAE de £13,182.38, un RMSE de £19,088.20, además de un R2 negativo, -0.0265. Un coeficiente de determinación negativo en principio indicaría un fallo importante en la capacidad predictiva del modelo. Pero observando la predicción a la vista, identificamos el error no como un fallo del diseño de la arquitectura del modelo sino como indicativo de una situación no contemplada en el diseño.

7.1.2. PROPHET


Cuando evaluamos el modelo en el conjunto de datos de test sin filtrar (**incluyendo el pico de ventas del día 14-11-2011**), obtenemos los siguientes resultados:

[ESCENARIO A] MÉTRICAS CON EL TEST COMPLETO (Incluyendo 14-Nov)

- MAE: £11,352.57
- RMSE: £16,338.66
- R2: 0.2480


7.1.3. OTROS MODELOS

Regresión Lineal Múltiple:




Cuando evaluamos el modelo en el conjunto de datos de test sin filtrar, encontramos un MAE de £13,381.53, un RMSE de £16,560.37, además de un R2 positivo de 0.23.

Regresión Polinómica de segundo grado:




Cuando evaluamos el modelo en el conjunto de datos de test sin filtrar, encontramos un MAE de £15,328.05, un RMSE de £22,258.52, además de un R2 negativo de -0.40..

Árbol de decisión:



Cuando evaluamos el modelo en el conjunto de datos de test sin filtrar, encontramos un MAE de £13,761.00, un RMSE de £19,785.80, además de un R2 negativo de -0.10.

XGBoost:



Cuando evaluamos el modelo en el conjunto de datos de test sin filtrar, encontramos un MAE de £15,721.83, un RMSE de £20,904.64, además de un R2 negativo de -0.23.

7.1.4. TABLA RESULTADOS MÉTRICAS FINALES PARA TEST COMPLETO (27 DÍAS)

Modelo	MAE (GBP)	RMSE (GBP)	R2	Valoración
Prophet	11,352.57	16,338.66	0,248	R2 positivo
Reg. Multilineal	11.381,53	16.560,37	0,23	R2 positivo
Random Forest	13.182,38	19.088,20	-0,0265	R2 negativo
Arbol de Decision	13.761,00	19.785,80	-0,1	R2 negativo
XGBoost	15.721,83	20.904,64	-0,23	R2 negativo
Reg. Polinómica (Grado 2)	15.328,05	22.258,52	-0,40	R2 negativo

Resultados sobre el test completo (27 días, incluido el 14-nov).

R2 negativo en casi todos los modelos de ventas: que significa

Un R2 negativo significa que el modelo predice peor que simplemente usar la media histórica como predicción para todos los días. Es una señal inequívoca de que existe al menos un evento en el periodo de test que el modelo no puede anticipar con las variables disponibles. La causa está identificada: el pedido mayorista del 14 de noviembre de 2011.

7.2. Hallazgo crítico: el outlier del 14 de noviembre

El 14 de noviembre de 2011 concentra 111.349 GBP en ventas, cuando la media histórica de los lunes es de 32.083 GBP. Esto supone un factor multiplicador de 3,5 veces sobre los lunes normales. Este comportamiento extremo, aislado en un único día, distorsiona las métricas de evaluación de cualquier modelo que no disponga de información externa sobre el evento causal.

7.3. Análisis forense del pedido mayorista

El 45,5% del total de ventas del 14 de noviembre procede de un único pedido (número de factura 576365) con tres características objetivas que apuntan inequívocamente a un pedido mayorista atípico:

Indicador	Valor	Interpretación
Valor del pedido	50.654 GBP	45,5% de las ventas totales del día.
CustomerID	NaN (nulo)	Sin cliente registrado. Típico de operaciones B2B directas.
Líneas de producto	99 líneas	Un pedido minorista normal tiene 5-15 líneas. Este es característico de un pedido mayorista
Tipo de productos	Stock navideño	Compra masiva de productos pre campaña navidad: "Paper chain kit 50's Christmas", "Jumbo bags"...
Ventas del día sin este pedido	60.695 GBP	Dentro del rango normal del periodo de Test.

Análisis forense del pedido 576365 del 14 de noviembre de 2011.

Decisión técnica: exclusión del 14-nov del conjunto de evaluación

La decisión correcta no es eliminar el pedido del dataset de entrenamiento (lo que no cambiaría las métricas del test), sino excluir ese día del conjunto de evaluación al calcular las métricas finales. El modelo fue diseñado para predecir ventas minoristas diarias ordinarias, y un pedido mayorista masivo esporádico no pertenece a esa categoría. Esta decisión se documenta con plena transparencia: se presentan primero los resultados con el test completo y luego los corregidos con su justificación formal.

7.4. Resultados sobre el test corregido (26 días)

7.4.1 RANDOM FOREST

Cuando hicimos ese ajuste, los resultados mejoraron bastante. El MAE bajó hasta £11,062.05, es decir, más de £2,100 de mejora. El RMSE, que es más sensible a valores extremos, también cayó mucho, hasta £14,103.08 (casi £5,000 menos). Y el R^2 pasó a ser positivo, llegando a 0.1925. Esto nos indica que, una vez quitamos ese caso tan raro, el modelo sí es capaz de explicar bastante bien cómo varían las compras normales de retail.

7.4.2. PROPHET

Realizamos la segunda evaluación **excluyendo el día 14-11-2011** en la prueba al igual que hemos hecho anteriormente para el modelo de Random Forest, y observamos los siguientes resultados:

```
[ ESCENARIO B ] MÉTRICAS CORREGIDAS (Excluyendo pedido mayorista del 2011-11-14)
- MAE: £9,654.85 (Mejora de £1,697.72)
- RMSE: £12,600.64 (Mejora de £3,738.01)
- R2: 0.3554
```

La conclusión más importante es la mejora del **MAE** y **RMSE** en el Escenario B:

Respecto a la métrica **RSME** se obtiene una mejora de **£3,738**. Como ya hemos comentado el RMSE penaliza con mucho los errores grandes, por lo que al excluir la fecha con el pico de ventas alto, el modelo mejora en la predicción del día a día.

Por otro lado, observamos que el **MAE mejoró en £1,697**, es decir en un día normal la predicción tiene un **margen de error de +/- £9,654**

Por último, comentar que el **R2 mejora considerablemente hasta alcanzar un 0.3554** cuando excluimos el pico del día 14 de noviembre. Este pico crea una variación enorme en el dataset. Aunque Prophet no llegó a predecir la cifra exacta del pico, probablemente en el escenario A (incluyéndolo) predijo una tendencia alcista para esa semana. Al quitar ese gran pico, los datos restantes son más "planos" o constantes, y al modelo le es más sencillo predecir

Conclusión: El modelo Prophet es bastante estable para el "día a día" de ventas minoristas, y su **error real** es mucho menor si ignoramos ventas excepcionales, como la del día 14 de noviembre.

7.5. TABLA RESULTADOS MÉTRICAS FINALES PARA TEST CORREGIDO (26 DÍAS)

Modelo	MAE (GBP) completo	MAE (GBP) corregido	RMSE completo	RMSE correg.	Mejora	R2 completo	R2 correg.
Prophet	11,352.57	9.654,85	16,338.66	12.600,64	22.88%	+0,24	+0,35
Reg. Multilineal	11.381,53	9.624,57	16.560,37	12.631,64	23,73%	+0,23	+0,35
Random Forest	13.182,38	11.062,05	19.088,20	14.103,08	26,12%	-0,0265	+0,1925
Arbol de Decision	13.761,00	11.369,23	19.785,80	13.590,11	31,31%	-0,1	+0,25
XGBoost	15.721,83	13.655,61	20.904,64	16.380,91	21,64%	-0,23	-0,09
Reg. Polinómica (Grado 2)	15.328,05	13655,36	22.258,52	19.530,43	12,26%	-0,40	-0,55

Comparativa de métricas con test completo vs test corregido. La mejora en RMSE oscila entre el 21% y el 31,3%.

7.6. EVALUACIÓN DE LOS RESULTADOS Y CONCLUSIONES DE DATASET VENTAS

Después de ejecutar todo el entorno de evaluación y revisar los resultados de la tabla, nos encontramos con algo bastante interesante y, al principio, un poco inesperado. El modelo que mejor funciona no es el más complejo, sino la regresión lineal múltiple, que es el más sencillo de todos los que probamos.

Cuando quitamos el dato anómalo del pedido mayorista del 14 de Noviembre, la regresión lineal consiguió los mejores resultados en todo: el MAE más bajo (£9.624,57), el RMSE más bajo (£12.631,64) y, además, el mejor R^2 , llegando a +0,35. En cambio, modelos más avanzados como XGBoost tuvieron un R^2 negativo (-0,09), lo que básicamente significa que predicen peor que usar simplemente la media.

Para entender por qué pasa esto, no hace falta complicarse mucho con los algoritmos, sino mirar mejor los datos y cómo los preparamos:

Primero, el papel clave del feature engineering. La regresión lineal funciona tan bien no porque sea un modelo potente, sino porque ya le dimos el trabajo bastante hecho. Al añadir variables como las medias móviles de 7 y 30 días o la tendencia (trend_1_vs_7), le estamos pasando la información importante ya resumida. Así, el modelo solo tiene que combinar esas señales. En el fondo, convertimos un problema complejo en algo mucho más directo, y ahí la regresión lineal va sobrada.

Segundo, el tema del ruido y el overfitting en los modelos de árboles. Los datos diarios de e-commerce son muy variables y están llenos de cosas aleatorias. Modelos como Random Forest o XGBoost son tan flexibles que intentan encontrar patrones incluso donde no los hay. Eso hace que se ajusten demasiado a los datos de entrenamiento. Luego, cuando llega un mes nuevo con su propio ruido, no generalizan bien. La regresión lineal, en cambio, al ser más simple, pasa por alto ese ruido y se queda con la tendencia general.

Tercero, lo que pasó con la regresión polinómica. Aquí vimos el caso contrario: al añadir demasiada complejidad (curvas, interacciones...), el modelo se ajustó demasiado al pasado. Así que cuando intenta predecir, se le va completamente de las manos ante pequeños cambios. Por eso acabó siendo el peor modelo, con un R^2 de -0,55.


Y por último, el impacto de quitar el dato anómalo del pedido B2B. Esto fue clave. Todos los modelos mejoraron bastante sus resultados, sobre todo en el RMSE, con mejoras de más del 20%. Esto nos confirma que el problema no era el modelo en sí, sino que estábamos mezclando un caso muy distinto (mayorista) con el comportamiento normal que queríamos predecir.

En resumen, todo esto refuerza una idea bastante clara: a veces, lo más simple funciona mejor. Si ya hemos trabajado bien los datos y extraído las señales importantes, no hace falta usar modelos súper complejos. La regresión lineal no solo es más fácil de entender y de usar en negocio, sino que además, en este caso, es la que mejor predice.

8. Resultados y evaluación - Dataset de Devoluciones

El modelo de devoluciones es el segundo eje del pipeline predictivo. Su objetivo es predecir el volumen diario de devoluciones en el periodo de test para calcular las ventas netas finales. Las devoluciones representan solo el 1,1% de las ventas brutas (16.823 GBP sobre 1.512.326 GBP). A diferencia del modelo de ventas, el dataset de devoluciones presenta un comportamiento estadístico mucho más estable: no existe un equivalente al pedido mayorista del 14 de noviembre, y la variación diaria es más contenida.

8.1. RANDOM FOREST:



Métricas para Random Forest Optimizado (Devoluciones):

- MAE: 399.08 (Error medio en dinero devuelto)
- RMSE: 524.18 (Sensible a grandes picos de devoluciones)
- R2: 0.1899 (Capacidad predictiva 0 a 1)


8.2. PROPHET

A diferencia de los resultados para el dataset de ventas, en el que Prophet destaca obteniendo buenos resultados, para el dataset de devoluciones podemos observar que los resultados no son nada buenos. Las predicciones de devolución que nos dan los resultados son al alza, es decir, predice una cantidad de devoluciones mucho más alta que la realidad para la mayoría de los días. Probablemente, esto se debe a que las devoluciones no siguen

un patrón estacional claro, hay mucha variación de unos días a otros. Por lo que no es capaz de establecer un patrón claro.


Métricas para Prophet:

- MAE: 629.68 (Error medio en dinero)
- RMSE: 778.79 (Sensible a grandes errores/outliers)
- R2: -0.7883 (Capacidad predictiva 0 a 1)



8.3. OTROS MODELOS


8.3.1. REGRESIÓN MULTILINEAL



Procesando: Regresión Multilineal...

-> Entrenando modelo directo (sin hiperparámetros)...
 -> Resultados del Test | RMSE: £491.36 | MAE: £374.39 | R2: 0.2881


8.3.2. REGRESIÓN POLINÓMICA (2º GRADO)



Procesando: Regresión Polinómica (Grado 2)...

-> Entrenando modelo directo (sin hiperparámetros)...
 -> Resultados del Test | RMSE: £581.05 | MAE: £470.42 | R2: 0.0045

8.3.3. ÁRBOL DE DECISIÓN



Procesando: Árbol de Decisión...

-> Optimizando hiperparámetros con RandomizedSearchCV...
 -> Mejores parámetros: {'min_samples_split': 20, 'min_samples_leaf': 12, 'max_depth': 3}
 -> Resultados del Test | RMSE: £600.76 | MAE: £472.92 | R2: -0.0642

8.3.4. XGBOOST



Procesando: XGBoost...

```
-> Optimizando hiperparámetros con RandomizedSearchCV...
-> Mejores parámetros: {'subsample': 0.8, 'n_estimators': 100, 'max_depth': 5, 'learning_rate': 0.01, 'gamma': 0.5, 'colsample_bytree': 0.8}
-> Resultados del Test | RMSE: £611.95 | MAE: £480.17 | R2: -0.1042
```

8.4. TABLA RESULTADOS MÉTRICAS FINALES PARA DATASET DEVOLUCIONES

Modelo	MAE (GBP)	RMSE (GBP)	R2	Valoración
Regresión Multilineal	374,39	491,36	+0,289	Modelo ganador. R2 positivo.
Random Forest	399,08	524,18	+0,1899	R2 positivo. Aceptable.
Regresión Polinómica (2º grado)	470.42	581.05	0,0	R2 neutro.
Arbol de Decision	472,92	600,76	-0,06	R2 negativo
XGBoost	480,17	611,95	-0,10	R2 negativo
Prophet	617,50	770,53	-0,70	R2 negativo. MAE y RMSE peores con respecto a otros modelos

Tabla 15. Resultados de los modelos sobre el dataset de devoluciones. Tres de los cuatro alcanzan R2 positivo.

La Regresión Multilineal gana con $RMSE = 491$ GBP, $MAE = 374$ GBP y $R^2 = +0,289$, explicando el 28,9% de la variabilidad de las devoluciones diarias. Su error de 374 GBP diarios representa el 0,67% del valor total diario de ventas brutas, un impacto prácticamente negligible sobre la predicción de ventas netas.

8.5. EVALUACIÓN DE LOS RESULTADOS Y CONCLUSIONES DE DATASET DEVOLUCIONES

A diferencia de lo que pasaba con las ventas, aquí nos encontramos con algo bastante más complicado: las devoluciones no siguen un patrón continuo. Son datos muy dispersos, con muchos días en los que no hay ninguna devolución y, de repente, picos que aparecen por motivos bastante impredecibles (problemas logísticos, clientes insatisfechos, etc.). Esto hace que el problema sea mucho más ruidoso y difícil de modelar.

A partir de los resultados, sacamos varias ideas claras:

Primero, se vuelve a confirmar que la regresión lineal múltiple es la que mejor funciona. Igual que con las ventas, es el modelo que consigue mejores métricas: un MAE de £374,39, un RMSE de £491,36 y un R^2 de +0,289. En un contexto así de irregular, que el modelo consiga explicar cerca del 30% de la variación ya es bastante buen resultado. Al final, su ventaja es que no se complica demasiado: al ser más “simple”, pasa del ruido diario y se queda con la tendencia general.

Luego tenemos el caso del Random Forest, que también lo hace bastante bien y queda en segunda posición con un R^2 de +0,1899. Aquí el mérito está en cómo lo ajustamos. Al limitar bastante su complejidad (menos profundidad, más restricciones en los splits), evitamos que se volviera loco intentando aprenderse cada pico raro. Básicamente, lo forzamos a fijarse solo en tendencias más grandes y no en casos aislados.

A partir de ahí, el rendimiento cae bastante. El árbol de decisión simple y XGBoost dan resultados peores, incluso con R^2 negativos. Esto quiere decir que, en la práctica, lo hacen peor que predecir siempre el valor medio.

En el caso de XGBoost, el problema viene de su propia naturaleza. Es un modelo que intenta reducir el error al máximo, así que cuando ve datos con picos raros, asume que hay patrones detrás e intenta aprenderlos. El problema es que esos picos no siguen ninguna lógica clara, así que acaba sobreajustando mucho (overfitting). Luego, cuando llegan datos nuevos con picos diferentes, falla bastante.

La regresión polinómica tampoco funciona bien. Al intentar ajustar curvas a unos datos tan irregulares, el modelo no es capaz de generalizar y básicamente se queda en algo muy cercano a la media, sin aportar valor.

Por último, el caso de Prophet es bastante claro. Es el peor modelo de todos en este escenario. Esto tiene sentido, porque Prophet funciona mejor cuando hay patrones estacionales claros (como fines de semana o campañas concretas). Pero las devoluciones no siguen un calendario tan definido. Al intentar forzar ese tipo de estructura en datos que son más bien aleatorios, las predicciones salen bastante distorsionadas.

En resumen, volvemos a ver la misma idea: en datos con mucho ruido y poca estructura clara, los modelos más simples y controlados suelen funcionar mejor que los más complejos.

9. FLUJO DE CAJA NETO

Para un equipo financiero u operativo dentro de un e-commerce, lo que realmente importa no es sólo cuánto se vende, sino cuánto dinero se queda de verdad en la empresa cada día. Es decir, el flujo de caja neto: ventas menos devoluciones.

Con esa idea en mente, hicimos la integración final de los modelos que habíamos entrenado.


Lo que hicimos fue bastante directo: cogimos los resultados del periodo de test (del 9 de noviembre al 9 de diciembre) de los dos modelos que mejor funcionaban, uno para ventas y otro para devoluciones. Luego los unimos usando la fecha como punto en común, para tener en una sola tabla tanto lo que entra como lo que sale.

A partir de ahí, aplicamos la lógica básica del negocio. Por un lado, calculamos la realidad: restamos las devoluciones reales a las ventas reales para ver cómo fue realmente la caja neta día a día. Por otro lado, hicimos lo mismo pero con las predicciones de los modelos, obteniendo así una estimación de ese flujo de caja.

Cuando comparamos ambas curvas, vimos que encajaban bastante bien. La línea de predicción sigue de cerca el comportamiento real del negocio, y las diferencias entre ambas no son muy grandes en general. De hecho, algo interesante es que algunos errores se compensan: cuando el modelo se pasa un poco estimando ventas, muchas veces también está estimando más devoluciones, así que al restar, el resultado final no se desvía tanto.

Al final, esto es lo importante: no nos quedamos solo en predecir variables por separado, sino que conseguimos algo útil a nivel negocio. Pasamos de modelos sueltos a una herramienta que permite anticipar la liquidez con cierta fiabilidad.

9.1. RANDOM FOREST



9.2. PROPHET


Predicción de ventas netas por día (ventas - devoluciones) **incluyendo** el pico ventas 14 de noviembre:

Tabla de ventas netas reales:

	date	actual_sales	actual_returns	real_final_sales
0	2011-11-09	62359.13	978.34	61380.79
1	2011-11-10	68593.52	520.65	68072.87
2	2011-11-11	52808.40	319.48	52488.92
3	2011-11-13	32213.29	83.10	32130.19
4	2011-11-14	111348.61	724.93	110623.68
5	2011-11-15	58121.76	149.04	57972.72

Tabla de predicción de ventas netas:

	date	predicted_sales	predicted_returns	predicted_final_sales
0	2011-11-09	57026.806135	969.721347	56057.084788
1	2011-11-10	61232.424096	1034.920771	60197.503325
2	2011-11-11	51845.429813	436.712497	51408.717316
3	2011-11-13	37219.386294	336.273665	36883.112629
4	2011-11-14	55855.238778	1720.079175	54135.159603
5	2011-11-15	55792.054287	1297.755844	54494.298442




Predicción de ventas netas por día (ventas - devoluciones) **excluyendo** el pico ventas 14 de noviembre:

Tabla de ventas reales:

	date	actual_sales	actual_returns	real_final_sales
0	2011-11-09	62359.13	978.34	61380.79
1	2011-11-10	68593.52	520.65	68072.87
2	2011-11-11	52808.40	319.48	52488.92
3	2011-11-13	32213.29	83.10	32130.19
4	2011-11-15	58121.76	149.04	57972.72


Tabla de predicción de ventas netas:

	date	predicted_sales	predicted_returns	predicted_final_sales
0	2011-11-09	57026.806135	969.721347	56057.084788
1	2011-11-10	61232.424096	1034.920771	60197.503325
2	2011-11-11	51845.429813	436.712497	51408.717316
3	2011-11-13	37219.386294	336.273665	36883.112629
4	2011-11-15	55792.054287	1297.755844	54494.298442




9.3. OTROS MODELOS


9.3.1. REGRESIÓN MULTILINEAL




9.3.2. REGRESIÓN POLINÓMICA (GRADO 2)



9.3.3. ÁRBOL DE DECISIÓN



9.3.4. XGBOOST



9.4. TABLA RESULTADOS MÉTRICAS FINALES PARA EL FLUJO DE CAJA NETO

Modelo	MAE (GBP) NETO	RMSE (GBP) NETO	R2 NETO	Valoración
Regresión Multilineal	9.758,10	12.696,95	+0,33	R2 positivo. Bastante buen resultado
Arbol de Decision	11.686,41	13.866,09	+0,20	R2 positivo. Aceptable
Random Forest	11.233,63	14.223,47	+0,16	R2 positivo.
Prophet	12.942,21	17.417,79	+0,13	R2 positivo.
XGBoost	13.751,53	16.544,79	-0,13	R2 negativo.
Regresión Polinómica (2º grado)	13.539,76	19.347,94	-0,55	R2 negativo. Inutilizable

Tabla 17. Comparativa de resultados de las métricas de evaluación

9.5. EVALUACIÓN DE LOS RESULTADOS Y CONCLUSIONES DEL FLUJO NETO

Cuando analizamos la previsión de la caja neta (ventas menos devoluciones), estamos básicamente cerrando todo el trabajo del proyecto. Aquí es donde juntamos dos cosas bastante distintas: por un lado, las ventas, que siguen un flujo más continuo, y por otro, las devoluciones, que son mucho más irregulares. Al mezclar ambas, el problema se vuelve más complejo porque aumenta bastante la variabilidad.

Después de ver los resultados, sacamos varias conclusiones bastante claras:

Una vez más, es el modelo que mejor funciona. En este caso, consigue un MAE de £9.758, un RMSE de £12.696 y un R^2 de +0,33. Esto, en un entorno tan cambiante como el retail, es un resultado muy sólido. Al final, se confirma la idea de que lo más simple puede funcionar mejor: como ya habíamos preparado bien los datos (medias móviles, tendencias, etc.), el modelo solo tiene que seguir la tendencia general sin meterse en el ruido diario.

El árbol de decisión (R^2 de +0,20) y el Random Forest (R^2 de +0,16) dan resultados aceptables, aunque no llegan al nivel de la regresión lineal. Aun así, hay algo interesante: a veces los errores se compensan. Por ejemplo, si el modelo se pasa estimando ventas, muchas veces también se pasa con las devoluciones, y al final el impacto en la caja neta no es tan grande.

Aunque antes no funcionaba bien con las devoluciones, aquí consigue un R^2 positivo (+0,13). Tiene sentido, porque sí capta bien los patrones de las ventas (que son más estacionales), y eso pesa bastante en el resultado final. De alguna forma, esa parte más estable ayuda a compensar el caos de las devoluciones.

XGBoost (R^2 de -0,13) y la regresión polinómica (R^2 de -0,55) vuelven a dar malos resultados. Al intentar capturar demasiados detalles en un problema que ya es bastante incierto, acaban sobreajustando. Es decir, aprenden demasiado bien el pasado, pero luego no saben responder cuando cambian los datos.

Al final, lo que vemos es que sí se puede construir una herramienta útil para anticipar la liquidez del negocio. Y lo curioso es que no hace falta usar modelos súper complejos. Con un buen trabajo previo de datos y un modelo más sencillo y transparente, conseguimos algo que funciona bien, es fácil de entender y además se puede usar en la práctica para tomar decisiones.

10. Decisiones y líneas de mejora

10.1. Decisiones metodológicas tomadas

- El proceso de limpieza de datos es exhaustivo y documentado, incluyendo la eliminación de duplicados, la detección de pares de corrección, el filtrado de anomalías mediante tres criterios alternativos y la eliminación de líneas no comerciales.
- La separación del dataset en ventas y devoluciones es una decisión metodológica justificada que permite un tratamiento diferenciado de cada flujo económico, contribuyendo a una mayor precisión en el modelado.
- El proceso de feature engineering va más allá de transformaciones estándar: cada variable creada tiene una justificación clara de por qué se incluye y qué aporta al modelo, cerrando la sección con un análisis de correlación que respalda las decisiones tomadas.
- El uso de **TimeSeriesSplit** es imprescindible en series temporales, evitando el data leakage entre particiones de entrenamiento y validación.
- La comparativa entre **GridSearchCV** y Randomized Search CV justifica la elección del método más eficiente computacionalmente.
- En esta primera fase seleccionamos un amplio número de algoritmos, profundizando para esta fase en Random Forest y Prophet.
- La detección y el tratamiento documentado del pedido mayorista del 14 de noviembre muestran que el equipo no se limitó a aplicar algoritmos, sino que supo interpretar los datos con criterio y tomar decisiones informadas a partir de ellos.
- El análisis del flujo neto cierra el proyecto combinando los resultados de ventas y devoluciones, lo que permite evaluar el impacto real de los modelos sobre la liquidez del negocio y extraer conclusiones sobre qué tipo de aproximación funciona mejor en un entorno con alta variabilidad.

10.2. Líneas de mejora para la memoria final

- Hacer una selección final de las features más relevantes y eliminar las menos relevantes para nuestros modelos.
- Usar otras técnicas de Machine Learning para nuestro conjunto de validación, y seleccionar la que mejor resultado muestre.
- Implementación de un modelo Deep Learning (Red Neuronal).