

MP6: Proyecto de IA y Big Data — Entrega Intermedia 2

Segmentación de Clientes en E-Commerce UK

Segmentación de Clientes mediante Clustering

Equipo de trabajo — Grupo E1

Adrián Sanz Llamas · Ioan Mark Bota · Juan Ramón Almirón López · Mario Martín Sánchez

0. Planteamiento Inicial.

En esta parte de la entrega vamos a realizar la segmentación de clientes mediante clustering probando varios modelos para elegir el que nos proporcione mejores resultados. El objetivo es identificar grupos de comportamiento similares y extraer conclusiones desde el punto de vista comercial. Para ello utilizaremos modelos no supervisados.

Partimos de un dataset transaccional que previamente hemos limpiado eliminado los CustomerID nulos, los cuales hemos analizado antes de ejecutar esta eliminación por si fuera o fuese necesario tratarlos de forma diferente. A partir de este dataset ya limpio, transformamos esta información a nivel cliente, permitiendo analizar cada cliente como una unidad de negocio.

Hemos construido nuevas variables RFM y otras adicionales de comportamiento, además de tratar outliers y comportamientos extremos que se explicarán en las siguientes secciones.

Los modelos elegidos para comprobar resultados han sido K-means, Agglomerative Clustering, DBSCAN y Gaussian Mixture Models, este último sin resultados concluyentes y válidos.

La siguiente tabla resume el punto de partida de los datos y las principales decisiones técnicas del proceso:

Indicador	Resultado
Dataset limpio de partida	390.600 transacciones válidas y 9 columnas
Cientes identificados	4.333 CustomerID únicos
Cientes outliers separados	217 clientes detectados con Isolation Forest
Cientes usados en clustering final	4.116 clientes normales
Variables finales del modelo	10 variables numéricas de comportamiento
Modelo final	K-Means
Número final de segmentos	4 clústeres
PCA 3D	87,86 % de varianza explicada acumulada
Resultado de negocio	4 segmentos: estándar bajo valor, fin de semana, activos valor medio y alto valor

Decisión final

- Se selecciona K-Means porque ofrece el mejor equilibrio entre métricas, estabilidad, ausencia de clientes sin asignar e interpretabilidad comercial.
- DBSCAN ajustado obtiene mejores métricas internas, pero solo genera 2 clústeres y deja 457 clientes como ruido.
- GMM se descarta por bajo Silhouette y alto solapamiento entre grupos.

Índice.

1.	Introducción y planteamiento del problema
2.	Dataset de partida y validación inicial
3.	Feature engineering por cliente
3.1	Estadística descriptiva del dataset de clientes
4.	Matriz de correlación y selección de variables
5.	Outliers y escalado
5.1	Detección de outliers con Isolation Forest
5.2	Escalado con RobustScaler
6.	Determinación del número óptimo de clusters
7.	Entrenamiento y evaluación de modelos
7.1	K-Means
7.2	Agglomerative Clustering
7.3	DBSCAN
7.4	Gaussian Mixture Model (GMM)
8.	Comparativa y elección del modelo final
9.	Perfilado e interpretación de segmentos

9.1	Tabla de perfil medio por segmento
9.2	Distribución de clientes por segmento
9.3	Perfil relativo de los segmentos
9.4	Descripción de segmentos
9.5	Estrategia de negocio recomendadas
10.	Conclusiones y líneas de mejora
10.1	Conclusiones técnicas
10.2	Conclusiones de negocio desde el punto de vista del Marketing
10.3	Puntos clave a analizar
10.4	Mejoras propuestas

1. Introducción y planteamiento del problema

El objetivo es segmentar clientes mediante técnicas de aprendizaje no supervisado. En este proceso, no existe una variable objetivo que predecir; se necesita obtener grupos coherentes, diferenciados entre sí y útiles para la toma de decisiones de negocio.

La unidad de análisis del clustering es el cliente. Por ello, las transacciones individuales se agregaron por CustomerID para construir un perfil único por cliente. Se combinan variables RFM, variables económicas derivadas, variables de variedad de compra y patrones temporales.

Planteamiento del problema

- Entrada: dataset transaccional limpio de ventas.
- Unidad de análisis: CustomerID.
- Salida: clúster asignado a cada cliente identificado.
- Criterio de éxito: segmentos interpretables y accionables desde negocio.

2. Dataset de partida y validación inicial

Partimos del dataset preprocesado y limpio de la parte de EDA contiene únicamente ventas válidas ya depuradas. No existen CustomerID nulos, descripciones nulas, fechas nulas, cantidades negativas, precios inválidos ni facturas canceladas. Esto permite trabajar directamente sobre una base transaccional limpia.

Comprobación	Resultado
Filas	390.600
Columnas	9
CustomerID nulos	0
Description nulas	0
InvoiceDate nulas	0
Quantity <= 0	0
UnitPrice <= 0	0
TotalPrice <= 0	0
Invoices canceladas	0
Clientes únicos	4.333
Facturas únicas	18.351
Productos únicos	3.659
Países presentes	37
Fecha mínima	2010-12-01
Fecha máxima	2011-12-09

La fecha máxima del dataset es 2011-12-09. Para calcular la recencia se utilizó la fecha de referencia de 2011-12-10, equivalente al día posterior a la última compra registrada.

3. Feature engineering por cliente

En esta fase se transformó el dataset transaccional en un dataset agregado por cliente, dejando una única fila por cada CustomerID. A partir de las facturas se calcularon variables RFM y de comportamiento, como la recencia de compra, frecuencia de pedidos, gasto total, productos distintos adquiridos, ticket medio, gasto mensual aproximado, productos por pedido, intervalo medio entre compras, pertenencia al mercado UK y proporción de compras realizadas en fin de semana.

Variable	Definición	Cálculo / criterio
Recency	Días desde la última compra	fecha_referencia - LastPurchase
Frequency	Número de pedidos únicos	nunique(InvoiceNo)
Monetary	Gasto total acumulado	sum(TotalPrice)
UniqueProducts	Productos distintos comprados	nunique(StockCode)
AverageOrderValue	Ticket medio por pedido	Monetary / Frequency
MonthlySpending	Gasto mensual aproximado	Monetary / ActiveMonths
Products_Per_Order	Variedad media por pedido	UniqueProducts / Frequency
PurchaseInterval	Días medios entre compras	Tenure / (Frequency - 1), si Frequency > 1
Is_UK	Cliente ubicado en Reino Unido	Country == United Kingdom
Weekend_Ratio	Proporción de compras en fin de semana	WeekendTransactions / TotalTransactions

También se generaron variables auxiliares como Tenure, ActiveMonths, AvgQuantityPerOrder, Weekend_Shopper y FavoriteDay, pero no todas se incorporaron al modelo final. Algunas se usaron solo para cálculos intermedios y otras se descartaron por redundancia, alta correlación o posible introducción de ruido.

Para FavoriteDay se asignó del 1 al 7 los días de la semana y se dejó con 0 para aquellos clientes que no tenían patrón de día favorito, esto confundirá al modelo porque pensaría que Domingo (7) valdría más que Lunes (1), así que lo convertimos en FavDay_1, FavDay_2, etc. y era una creación innecesaria de variables.

En concreto, FavoriteDay se excluyó porque su inclusión requería One-Hot Encoding(codificación adicional), aumentaba la dimensionalidad y podía ser poco fiable en clientes con pocas compras. En su lugar, se mantuvo Weekend_Ratio, al aportar información temporal de forma más estable.

FavoriteDay se pensó por si nos podía dar información útil sobre patrones de comportamiento potenciales asociados a B2B o B2C, y luego la transformamos en una variable binaria llamada BusinessDay_Favorite para identificar el día favorito del cliente correspondiente a un día laborable. Al final no funcionó y decidimos eliminar las dos y mantener solo Weekend_Ratio como se ha comentado antes.

Tabla resumen.

Variable auxiliar	Uso	Decisión final
Tenure	Días entre primera y última compra	Excluida: alta correlación con Frequency
Tenure_Adjusted	Evitar divisiones entre cero	Auxiliar, no entra al modelo
ActiveMonths	Calcular MonthlySpending	Auxiliar, no entra al modelo
AvgQuantityPerOrder	Unidades medias por pedido	Excluida: correlacionada con AverageOrderValue
Weekend_Shopper	Binaria de compra en fin de semana	Excluida: se mantiene Weekend_Ratio por aportar más información
FavoriteDay	Día favorito de compra	Excluida: categórica temporal con riesgo de ruido

3.1 Estadística descriptiva del dataset de clientes tabla resumen.

Variable	Media	Mediana	Mínimo	Máximo	Lectura
Recency	93,25	51,00	1,00	374,00	Hay clientes recientes y clientes inactivos que elevan la media
Frequency	4,24	2,00	1,00	204,00	La mayoría compra pocas veces; existen clientes muy recurrentes
Monetary	1.951,72	659,41	2,90	279.138,02	Distribución muy asimétrica por clientes de gran valor
TotalQuantity	1.146,57	376,00	1,00	196.844,00	Volumen muy concentrado en pocos clientes
UniqueProducts	61,41	35,00	1,00	1.785,00	Algunos clientes compran gran diversidad
AverageOrderValue	379,67	289,35	2,90	19.809,75	Ticket medio con valores extremos
MonthlySpending	413,29	239,18	2,90	39.619,50	Intensidad de gasto muy variable
PurchaseInterval	47,76	28,60	0,00	366,00	Muchos clientes tienen una sola compra o compras espaciadas


La lectura principal de las estadísticas es que la media suele ser superior a la mediana en variables económicas y de volumen. Esto confirma distribuciones asimétricas y presencia de clientes de muy alto valor, lo que justifica revisar outliers y aplicar RobustScaler.

Estadísticas descriptivas:								
	count	mean	std	min	25%	50%	75%	max
Recency	4,333.00	93.25	100.13	1.00	18.00	51.00	143.00	374.00
Frequency	4,333.00	4.24	7.60	1.00	1.00	2.00	5.00	204.00
Monetary	4,333.00	1,951.72	8,423.87	2.90	303.16	659.41	1,624.05	279,138.02
TotalQuantity	4,333.00	1,146.57	4,744.08	1.00	159.00	376.00	988.00	196,844.00
UniqueProducts	4,333.00	61.41	85.27	1.00	16.00	35.00	77.00	1,785.00
Tenure	4,333.00	130.56	132.25	0.00	0.00	92.00	252.00	373.00
AverageOrderValue	4,333.00	379.67	556.38	2.90	176.68	289.35	423.79	19,809.75
AvgQuantityPerOrder	4,333.00	228.77	310.29	1.00	92.50	160.78	271.93	7,824.00
MonthlySpending	4,333.00	413.29	1,060.93	2.90	131.70	239.18	417.95	39,619.50
Products_Per_Order	4,333.00	18.83	17.59	0.20	8.00	14.00	24.00	259.00
PurchaseInterval	4,333.00	47.76	63.39	0.00	0.00	28.60	68.75	366.00
Is_UK	4,333.00	0.90	0.30	0.00	1.00	1.00	1.00	1.00
Weekend_Ratio	4,333.00	0.13	0.28	0.00	0.00	0.00	0.09	1.00
FavoriteDay	4,333.00	3.55	1.85	1.00	2.00	3.00	5.00	7.00

4. Matriz de correlación y selección de variables

Se calculó una matriz de correlación de Spearman entre las variables candidatas. Elegimos spearman porque es más robusto ante distribuciones no normales y presencia de valores extremos, como los datos presentes en las variables de Monetary o Frequency.

Spearman mide la intensidad y dirección de la relación monótonica entre dos variables, tomando valores entre -1 y 1. Así que esta métrica resulta adecuada en este caso porque las variables presentan distribuciones asimétricas y valores extremos.



4.1 Detección de variables con alta correlación

Variable 1	Variable 2	Correlación
Monetary	TotalQuantity	0,93
Frequency	Tenure	0,90
AverageOrderValue	AvgQuantityPerOrder	0,81
Frequency	Monetary	0,81

En un primer momento probamos con un umbral de **0.90** pero solo detectaba un relación redundante entre Monetary y TotalQuantity, esto nos proporcionaba poca información así que ajustamos el umbral a **0,80**, lo que nos permitió detectar cuatro pares con correlación fuerte:

- Monetary con TotalQuantity,
- Frequency con Tenure,
- AverageOrderValue con AvgQuantityPerOrder
- Frequency con Monetary,

4.2 Eliminación y selección final de variables

Según el análisis de correlación del apartado anterior, ambas variables de cada par están midiendo prácticamente la misma dimensión del comportamiento del cliente, por lo que incluir las dos sesgaría el modelo hacia esa dimensión sin que sea una decisión consciente.

Las variables eliminadas fueron:

TotalQuantity fue descartada por su alta correlación con Monetary, ya que ambas reflejan en gran medida el volumen económico del cliente.

También se eliminó Tenure por su fuerte relación con Frequency, manteniendo esta última y Monetary al formar parte del enfoque RFM con dimensiones diferentes y representar directamente la recurrencia de compra.

Del mismo modo, se descartó AvgQuantityPerOrder al estar correlacionada con AverageOrderValue, manteniendo esta última por su mayor interpretación económica.

Finalmente, se excluyó FavoriteDay del modelo principal, ya que se trata de una variable categórica temporal que requeriría codificación adicional y podría introducir ruido, especialmente en clientes con pocas compras. Se mantuvo Weekend_Ratio por aportar una medida continua y más estable del comportamiento temporal de compra.

Las variables finales seleccionadas:

Variables finales antes de modelado
Recency, Frequency, Monetary, UniqueProducts, AverageOrderValue, MonthlySpending, Products_Per_Order, PurchaseInterval, Is_UK, Weekend_Ratio

5. Outliers y escalado

5.1 Detección de outliers con Isolation Forest

Se aplicó Isolation Forest con contamination=0.05 para identificar clientes con patrones atípicos considerando simultáneamente todas las variables finales mencionadas en el apartado anterior. Esta técnica evita definir umbrales manuales por variable y permite detectar anomalías multivariantes.

Indicador	Valor
Cientes antes de outliers	4.333
Contamination	0,05

Clientes normales	4.116
Outliers detectados	217
Porcentaje de outliers	5,01 %
Variables usadas	10

Los outliers no se eliminaron definitivamente. Fueron separados para análisis posterior porque pueden representar clientes mayoristas o comportamientos comerciales relevantes. El modelo principal se entrenó con clientes normales para evitar distorsiones en las distancias.

5.2 Escalado con RobustScaler

El escalado fue necesario porque las variables tienen magnitudes muy diferentes. Monetary y AverageOrderValue pueden tomar valores de cientos o miles, mientras que Is_UK y Weekend_Ratio están acotadas entre 0 y 1. Se eligió RobustScaler porque centra por mediana y escala por rango intercuartílico, siendo más resistente a valores extremos que StandardScaler.

Dataset	Dimensiones
X_modelo antes de outliers	(4.333, 10)
X_modelo_normales	(4.116, 10)
X_scaled	(4.116, 10)
df_escalado con CustomerID	(4.116, 11)

6. Métricas para selección del número óptimo de clústeres

La **inercia** mide la dispersión interna de cada clúster; disminuye siempre al aumentar K, por lo que no se busca el valor más bajo sino el punto donde esa reducción se estabiliza (método del codo).

El **índice Silhouette** evalúa qué tan bien encaja cada punto en su clúster frente al más cercano, con rango entre -1 y 1; valores más altos indican clústeres mejor definidos, aunque tiende a favorecer valores bajos de K.

El **índice Davies-Bouldin** compara la compacidad interna de cada clúster con su separación respecto a los demás; valores más bajos indican clústeres más compactos y separados entre sí. El **índice Calinski-Harabasz** mide la ratio entre la dispersión entre clústeres y la dispersión interna; valores más altos indican una separación más clara, aunque también tiende a favorecer K bajos.

7. Entrenamiento y evaluación de modelos

7.1 K-Means

Es el modelo más común en clustering, por su rapidez y sencillez.


Cómo funciona: Le debemos indicar cuántos grupos (clusters) para agrupar, es decir, el valor “K”. El algoritmo coloca “K” puntos aleatorios (llamados “**centroides**”) y cada cliente se une al centroide más cercano. Luego, los centroides se mueven al centro de sus nuevos grupos y el proceso se repite hasta que los grupos dejan de cambiar.

Este modelo es ideal para clusters con forma circular o esférica y grupos de tamaño similar.

Prueba inicial de entrenamiento del modelo

Para determinar el número óptimo de clústeres se evaluó K-Means para valores de K entre 2 y 10, utilizando `random_state=42` y `n_init=10`. La selección se apoyó en cuatro métricas complementarias.

K	Inertia	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	47.681,69	0,64	0,58	4.957,43
3	36.659,07	0,42	1,18	3.841,58
4	30.035,94	0,44	1,04	3.427,26
5	26.119,26	0,36	1,13	3.109,29
6	23.285,41	0,27	1,17	2.889,51
7	21.413,96	0,26	1,18	2.677,58
8	19.807,31	0,26	1,21	2.528,23
9	18.634,81	0,25	1,21	2.383,13
10	17.755,44	0,23	1,20	2.245,30



Aunque las métricas apuntaban a K=2 como valor óptimo, se descartó por generar una segmentación demasiado simple para ser útil desde el punto de vista de negocio.

Entrenamiento del modelo tras prueba inicial

K-Means se entrenó con `n_clusters=4`, `random_state=42` y `n_init=10`. Fue usado como modelo base por su sencillez, estabilidad e interpretabilidad en problemas de segmentación de clientes.

El entrenamiento se realizó sobre las 10 variables escaladas originales, manteniendo la interpretabilidad de las variables de negocio.

Resultados de las métricas del entrenamiento

Métrica / distribución	Valor
Silhouette	0,4418
Davies-Bouldin	1,0420
Calinski-Harabasz	3.427,26

- **Silhouette: 0,44:** este valor nos indica, que tenemos una estructura clara, no es ruido al azar.
- **Davies-Bouldin: 1,04:** nos indica que los grupos son distintos entre sí; no se confunden.
- **Calinski-Harabasz: 3.427:** nos indica que los patrones encontrados son fuertes y estables.


Conclusión: Las métricas validan que el modelo de segmentación K-Means que estamos usando es **técnicamente correcto y empresarialmente útil**.

A diferencia de la regresión, en el que las métricas tenían mucho peso en la decisión, en el caso del clustering, no lo son tanto, por lo que nos apoyaremos mucho en la **visualizaciones gráficas para la interpretación de los resultados del entrenamiento y las decisiones finales**.

Visualización PCA 2D

Al finalizar el entrenamiento del modelo, se usa PCA, el cual tiene el objetivo de reducir el número de dimensiones, es decir reducir el número de variables con que se entrenó el modelo (en este caso 10 variables), para poder representar gráficamente los datos.

Por tanto, señalar que PCA se utiliza exclusivamente para realizar la visualización justo después de finalizar el entrenamiento.



PCA 2D de la distribución de los clusters + Varianza explicada

Este gráfico de **PCA** (Análisis de Componentes Principales) es la prueba visual de que la **segmentación tiene una estructura lógica y no es aleatoria**. Aquí está la interpretación de lo que vemos:

Los ejes y la varianza

- **PC1 (Eje horizontal):** La varianza explica el **64.92%** de la información. **Es la dirección más importante**. En datos de clientes, este eje suele representar el **volumen / valor** (quien está más a la derecha gasta más (monetary) y compra más seguido (frecuencia)).
- **PC2 (Eje vertical):** La varianza explica el **15.52%**. Suele representar una métrica secundaria, como la **recencia** o el comportamiento del fin de semana.
- **Total:** Juntos explican más del **80%** de la variabilidad de tus datos, lo cual es **un resultado excelente**.

Conclusiones

1. **Segmentación clara:** No se aprecian puntos de diferentes colores entremezclados. Los colores están agrupados en zonas definidas, lo que significa que el algoritmo **K-Means ha identificado patrones reales**.
2. **Gradiente de valor:** Existe un camino claro desde el naranja -> verde -> rojo. Esto representa el **ciclo de vida del cliente**.
3. **Presencia de outliers:** Los puntos rojos que están muy a la derecha (cerca del valor 12 en PC1) son los clientes críticos.
4. **Fronteras definidas:** Las líneas de separación entre los clusters son bastante rectas, lo que sugiere que las variables que definen estos grupos están bien correlacionadas.

Tabla de métricas de ventas (valores medios) por cada clúster

Para obtener más contexto e información sobre la segmentación de los clientes en los clústers, y poder interpretar posteriormente los clientes de cada clúster, se calcula la media de los valores de cada métrica de venta en cada uno de los clústers, obteniendo los siguientes resultados:

Cluster	Recency	Frequency	Monetary	UniqueProducts	AverageOrderValue	MonthlySpending	Products_Per_Order	PurchaseInterval	Is_UK	Weekend_Ratio	Num_Clientes
0	113.23	2.24	634.37	34.62	295.59	271.03	17.41	47.87	0.91	0.00	2786
1	105.72	2.30	602.79	50.43	264.69	257.30	23.70	40.32	0.98	0.94	341
2	51.98	4.45	1,327.26	77.47	308.06	259.38	18.71	74.35	0.94	0.39	420
3	29.07	10.03	4,073.33	129.76	504.04	543.29	16.76	37.70	0.91	0.06	569

Clúster 0

- Son clientes de bajo volumen de gasto (Monetary £634 total) y que llevan de media más de **3 meses (113,23 días)** sin comprar.
- Compran poco (Monetary bajo) y muy de vez en cuando (Frequency baja). y no compran en fin de semana (Weekend_Ratio 0.00).

Clúster 1

- Tienen un gasto (Monetary = £602) y frecuencia (2.3), muy similares al Cluster 0, pero el dato clave es que sus **hábitos de compras** son casi siempre **en fin de semana**: *Weekend_Ratio = 0.94*.

Clúster 2

- Mejor comportamiento que los clústeres 0 y 1 en **recencia, frecuencia y gasto**. Presenta **PurchaseInterval** alto, lo que indica que compra con cierta recurrencia, pero con intervalos más largos entre compras.

Clúster 3

- Tiene la menor recencia media, la mayor frecuencia de compras, el mayor gasto (monetary), y mayor UniqueProducts, mayor AverageOrderValue y mayor MonthlySpending. Es decir, son clientes recientes, frecuentes, con alto gasto y alto valor medio.

Número de clientes en cada clúster

También obtenemos de la tabla anterior (columna “**Num_Clientes**”), el número total de clientes que tiene cada clúster, en el cual podemos ver una clara diferencia del **Cluster 0 (2.786 clientes)** sobre el resto (entre 341 y 569 clientes)

Cluster 0	2.786 clientes
Cluster 1	341 clientes
Cluster 2	420 clientes
Cluster 3	569 clientes



Distribución de clientes por clúster en K-Means.

Prueba con k igual a 5

Se realizó un segundo entreno con un número de k igual a 5 , al comparar las distribuciones de clientes, se observó que K=5 no aportaba un segmento nuevo sino que dividía el clúster mayoritario de K=4 (2.786 clientes) en dos subgrupos (343 y 2.441), mientras el resto de clústeres quedaban prácticamente inalterados. Además, al analizar las medias de cada clúster, se comprobó que uno de esos dos subgrupos presentaba un Weekend_Ratio de 0.93 , un perfil de comprador de fin de semana que K=4 ya había capturado como clúster independiente. K=5 no estaba descubriendo un segmento nuevo sino replicando un patrón ya existente dentro del clúster mayoritario. Esto se confirma con las métricas: al pasar de K=4 a K=5, el índice Silhouette baja de 0.44 a 0.36, Davies-Bouldin empeora de 1.04 a 1.13 y Calinski-Harabasz cae de 3.427 a 3.109, lo que indica que la división fuerza una separación que no está respaldada por los datos. Se seleccionó K=4 como solución final por mantener una calidad estadística aceptable y producir cuatro segmentos bien diferenciados e interpretables.

Cluster	Recency	Frequency	Monetary	UniqueProducts	AverageOrderValue	MonthlySpending	Products_Per_Order	PurchaseInterval	Is_UK	Weekend_Ratio	Num_Clientes
0	105.27	2.31	602.61	50.58	264.11	257.30	23.68	40.33	0.98	0.93	343
1	113.50	2.38	595.70	31.92	245.16	207.37	14.52	51.49	0.92	0.00	2441
2	92.96	2.23	1,440.25	68.35	686.23	738.20	34.80	30.84	0.84	0.00	487
3	52.15	4.49	1,357.74	77.62	311.40	258.72	18.50	74.09	0.94	0.38	427
4	21.97	11.97	4,560.13	139.47	415.69	470.08	13.36	32.58	0.93	0.07	418

7.2 Agglomerative Clustering

Cómo funciona: es como un árbol genealógico, pero a la inversa. Empieza considerando que **cada cliente es un cluster individual**. Luego, busca a los dos clientes más parecidos y los une en un grupo. Después, une los grupos más cercanos entre sí, y así sucesivamente hasta que todos están en un solo gran grupo. Al igual que en K-Means, nosotros como analistas, decidiremos cómo agruparlos, indicando manualmente el número de grupos (clusters) deseado a través de la variable "K".

Es ideal para entender relaciones jerárquicas (ej. subgrupos dentro de grupos grandes).

Entrenamiento del modelo

El clustering jerárquico aglomerativo se entrenó con **n_clusters=4** y **linkage=ward**. “ward” minimiza la varianza y es comparable con K-Means al trabajar sobre variables escaladas.

Resultados de las métricas del entrenamiento


Métrica / distribución	Valor
Silhouette	0,3830
Davies-Bouldin	1,0684
Calinski-Harabasz	3.041,53

- **Silhouette: 0,38:** este valor nos indica, que tenemos una estructura clara, no es ruido al azar. Ligeramente menor a K-Means (0,44)
- **Davies-Bouldin: 1,068:** nos indica que los grupos son distintos entre sí; no se confunden.
- **Calinski-Harabasz: 3.041:** nos indica que los patrones encontrados son fuertes y estables.


Conclusión: Las métricas validan que el modelo de segmentación Agglomerative que estamos usando es **técnicamente correcto** y **empresarialmente útil**.

Visualización PCA 2D

Al finalizar el entrenamiento del modelo, se usa PCA para visualizar los resultados. Añadiremos de nuevo aquí la imagen del PCA de K-Means para comparar ambas.



Varianza explicada PCA 2D:
PC1: 64.92%
PC2: 15.52%
Total: 80.43%



Varianza explicada PCA 2D:
PC1: 64.92%
PC2: 15.52%
Total: 80.43%

Lo primero que debemos destacar, es que la **varianza es idéntica en ambos modelos (80.43%)**. La explicación es que para crear el PCA (al igual que para el entrenamiento de ambos) hemos usado exactamente **el mismo conjunto de**

datos. Por tanto, que la varianza sea la misma es bueno, ya que nos permite hacer una **comparativa más justa entre los dos modelos.**

Procedemos a comparar la distribución de los puntos en ambas gráficas:

Aunque el gráfico de fondo sea idéntico, es decir observamos que los puntos están distribuidos de manera similar, se aprecian varias diferencias en lo que se refiere a las **“fronteras” de los colores:**

- **Agglomerative** crea formas más sinuosas y presenta agrupaciones más irregulares, sobre todo en la parte izquierda con los puntos Naranja y Azules entremezclados, con lo que **es más difícil apreciar la separación de los clusters con este modelo.**
- **K-Means** crea fronteras más rectas o circulares y más definidas, **apreciándose más claramente la separación de los clusters.**

Tabla de métricas de ventas (valores medios) por cada clúster

Al igual que ya hicimos para K-Means, para obtener información sobre los clientes de los clústers, se calcula la media de los valores de cada métrica de venta:

Cluster	Recency	Frequency	Monetary	UniqueProducts	AverageOrderValue	MonthlySpending	Products_Per_Order	PurchaseInterval	Is_UK	Weekend_Ratio	Num_Clientes
0	112.70	2.21	718.65	36.87	322.13	300.15	18.11	48.04	0.91	0.00	2818
1	26.67	10.12	3,619.52	118.91	372.20	390.08	13.30	38.62	0.90	0.09	602
2	119.04	1.81	475.81	43.08	262.39	273.02	24.83	22.39	0.98	1.00	253
3	59.00	4.12	1,181.91	75.88	297.38	250.95	19.54	80.14	0.97	0.49	443

Agglomerative - Tabla de métricas por clúster

Comparando los valores obtenidos con Agglomerative, con los de K-Means, observamos que son valores muy parecidos en muchas de las métricas, con lo cual **obtenemos conclusiones similares** a las que detallamos en esta misma sección para K-Means.

Cluster	Recency	Frequency	Monetary	UniqueProducts	AverageOrderValue	MonthlySpending	Products_Per_Order	PurchaseInterval	Is_UK	Weekend_Ratio	Num_Clientes
0	113.23	2.24	634.37	34.62	295.59	271.03	17.41	47.87	0.91	0.00	2786
1	105.72	2.30	602.79	50.43	264.69	257.30	23.70	40.32	0.98	0.94	341
2	51.98	4.45	1,327.26	77.47	308.06	259.38	18.71	74.35	0.94	0.39	420
3	29.07	10.03	4,073.33	129.76	504.04	543.29	16.76	37.70	0.91	0.06	569

K-Means - Tabla de métricas por clúster

IMPORTANTE: El número que identifica a cada cluster (en la columna “Cluster” de la tabla) **no coinciden entre ambos modelos.** Si comparamos en ambas tablas los valores de las principales métricas (Recency, Frequency, Monetary, uniqueProducts) de cada cluster, podemos obtener qué cluster serían **“el mismo tipo de cliente”** en en ambos modelos:

Agglomerative	K-Means
Cluster 0	Cluster 0
Cluster 1	Cluster 3
Cluster 2	Cluster 1
Cluster 3	Cluster 2


Número de clientes en cada clúster

También obtenemos de la columna “**Num_Clientes**”, el número total de clientes que tiene cada clúster, en el cual podemos ver una clara diferencia en número total de clientes, del **Cluster 0 (2.818 clientes)** sobre el resto (602, 253, y 443 clientes), al igual que sucedía también con K-Means.

Cluster 0	2.818 clientes
Cluster 1	602 clientes
Cluster 2	253 clientes
Cluster 3	443 clientes

Resumen comparativo número total de clientes por cluster

Comparativa de distribución de clústeres: K-Means vs Agglomerative



Conclusiones

Agglomerative generó perfiles similares a K-Means, pero **obtuvo métricas inferiores, además de observarse una peor distribución de los clusters en el PCA.**

Por tanto, es útil como validación comparativa, pero **no supera al modelo K-Means.**

7.3 DBSCAN

Es un modelo basado en densidad, es decir, este modelo no habrá que indicarle el número de grupos (K), sino que él mismo intentará buscar e identificar el número de grupos (clusters).

Cómo funciona: busca zonas donde los puntos están muy apretados (alta densidad). Si un punto tiene suficientes vecinos cerca, se crea un cluster. Si un punto está muy solo y no llega al mínimo de vecinos, lo marca como **ruido o outlier**.

Ideal para: detectar valores atípicos y encontrar grupos con formas irregulares (no necesariamente círculos).

Entrenamiento y ajuste de hiperparámetros

DBSCAN fue evaluado porque no requiere indicar K previamente y permite detectar ruido. La primera prueba usó **eps=0,8 y min_samples=10**. Esta configuración generó **5 clústeres**, de los cuales uno es el que añade como “-1”, el cual es el cluster donde añade los clientes que detecta como **outliers / ruido (1.595 clientes)**, equivalentes al 38,75 %, por lo que resultó demasiado restrictiva.






Figura 10. Distribución de etiquetas en DBSCAN inicial.




DBSCAN inicial proyectado en PCA 2D.


Se realizó una búsqueda de parámetros con **eps** entre 0,8 y 3,0 y **min_samples** en 5, 10, 15 y 20. El objetivo fue reducir el ruido sin fusionar todos los clientes en un único grupo.



Porcentaje de ruido según eps y min_samples.



Número de clústeres según eps y min_samples.



Silhouette Score según eps y min_samples.


Resultados de los entrenamientos con los diferentes hiperparámetros

eps	min_samples	Clústeres	Ruido	% ruido	Silhouette	Davies-Bouldin
1,20	15	2	950	23,08 %	0,79	0,25
1,50	20	2	611	14,84 %	0,74	0,29
1,50	10	2	457	11,10 %	0,72	0,32
1,80	20	2	357	8,67 %	0,70	0,33
1,20	10	4	794	19,29 %	0,46	0,57

La mejor configuración para DBSCAN es **eps=1.80 y min_samples=20**. Esta combinación logró el equilibrio óptimo: mantiene una métrica de separación muy alta (**Silhouette 0.70** y un **Davies-Bouldin de 0.33**, lo cual indica que los dos clusters encontrados son sólidos y puros. Además es la configuración en DBScan que **más minimiza el ruido (8,67%)**. Aun así, **su segmentación** es peor que los otros dos modelos que hemos probado, ya que **deja 357 clientes sin asignar**.

Visualización PCA 2D

Realizamos una visualización de los resultados del DBSCAN ajustado, en el que obtuvimos **2 clusters**, y añadimos el **cluster “-1”**, el cual nos indica el **“ruido / outliers”**:



DBSCAN ajustado proyectado en PCA 2D.

Los resultados que podemos observar en el gráfico son muy reveladores:

El Cluster -1 (Naranja): Ruido / Outliers

- La gran cantidad de puntos naranjas (**Cluster -1**) indica que DBSCAN considera que muchos de los clientes tienen comportamientos "erráticos" o únicos que no se agrupan fácilmente.
- La conclusión es que tenemos un dataset con mucha dispersión y DBSCAN es muy estricto: si un cliente no tiene "vecinos" con métricas casi idénticas, lo expulsa del análisis grupal.

Cluster 0 (Azul)

- Ha detectado un núcleo denso de clientes (la mayoría) que comparten comportamientos estándar.

Cluster 1 (Verde):

- Ha logrado identificar una columna muy estrecha y densa en el extremo derecho. Estos son clientes con un comportamiento **extremadamente similar entre sí** pero muy alejados del resto.

Conclusiones

- **DBSCAN no es ideal para nuestro dataset de clientes y por tanto para su segmentación** ya que ha dejado gran cantidad de clientes como "ruido".
- **Útil para detectar anomalías:** Los puntos naranjas que están muy arriba o muy a la derecha pueden ser nuestros verdaderos **outliers**. DBSCAN podría ayudarnos más como un detector de "clientes extraños" o posibles errores de datos, que como un segmentador de clientes.

- **En resumen:** DBSCAN te confirma que nuestro dataset tiene un núcleo sólido (Azul), pero que hay demasiado "ruido" para usar este modelo. **K-Means sigue siendo nuestra mejor opción.**

7.4 Gaussian Mixture Model (GMM)

Es una versión más sofisticada y "flexible" de K-Means.

Cómo funciona: en lugar de asignar a un cliente a un solo grupo de forma rígida, GMM asume que los datos provienen de varias **campanas de Gauss* superpuestas. Proporciona una probabilidad de estar en un clúster u otro. En nuestro caso, un ejemplo podría ser: "Este cliente tiene un 80% de ser VIP y un 20% de ser Clase Media".

Ideal para: Clusters que se solapan o que tienen formas elípticas y alargadas.

***Campana de gauss:** representación gráfica de la distribución de un conjunto de datos. Se caracteriza por:

- **Media:** El punto más alto de la campana, donde se concentra el promedio de todos los datos.
- **Desviación Estándar:** Qué tan ancha o estrecha es la campana (qué tan dispersos están los datos).

Entrenamiento del modelo

GMM se entrenó con **n_components=4, covariance_type=full y random_state=42**. Se probó como alternativa probabilística a K-Means, capaz de modelar clústeres con formas más flexibles.

Resultados de las métricas del entrenamiento


Métrica / distribución	Valor
Silhouette	0,0485
Davies-Bouldin	3,1950
Calinski-Harabasz	311,01

- **Silhouette: 0,048:** valor muy cercano a 0, significa que los grupos están **solapados casi por completo**. No hay una separación clara.
- **Davies-Bouldin: 3,195:** en esta métrica buscamos el valor más bajo posible (cercano a 0). Este valor tan alto indica que la "dispersión" dentro de cada grupo es enorme y que los grupos están muy pegados entre sí. Los clusters no son compactos.
- **Calinski-Harabasz: 311,01:** en los modelos anteriores teníamos valores por encima de **3.400**. Bajar a **311** es una caída drástica, que indica que la **estructura que ha encontrado GMM es muy débil**.

Conclusión: Las métricas nos indican que GMM está haciendo una segmentación "borrosa", con clusters poco definidos.

Visualización PCA 2D

Los resultados de las métricas ya nos han avanzado que los resultados de distribución de clusters no serán muy buenos, realizamos el PCA para sacar conclusiones:



En la gráfica confirmamos, por qué las métricas de Silhouette y Davies-Bouldin fueron tan bajas para este modelo observando los siguientes patrones:

- **Solapamiento extremo:** a diferencia de otros modelos por ejemplo el PCA de K-Means (donde las fronteras eran claras), en el GMM los colores están mezclados. Vemos puntos rojos (Cluster 1) debajo de nubes verdes (Cluster 2) y azules (Cluster 3).
- **Las estructuras son lineales, en vez de circulares:** GMM está "forzando" campanas de Gauss sobre datos que tienen formas alargadas y sesgadas.

Conclusiones

Las métricas de Silhouette casi nulo y Davies-Bouldin elevado, **indican fuerte solapamiento entre clusters**. La visualización PCA lo confirma, donde no se observan clusters bien definidos.

Por ello se descarta como modelo final.


8. Comparativa y elección del modelo final



En la sección anterior, ya hemos ido realizando la comparativa entre los modelos, y hemos podido obtener resultados claros, para la elección final del modelo.

En la siguiente tabla mostramos un resumen comparativo de los cuatro modelos usados:


Modelo	Clústeres	Ruido	% ruido	Silhouette	Davies-Bouldin	Calinski-Harabasz	Valoración
K-Means	4	0	0,00 %	0,44	1,04	3.427,26	Alta: 4 segmentos accionables, mejores métricas que Agglomerative
Agglomerative	4	0	0,00 %	0,38	1,07	3.041,53	Media-alta: similar a K-Means, peores métricas
DBSCAN ajustado	2	357	8,67 %	0,70	0,33	4.362,56	Métrica alta, pero segmentación pobre y ruido
GMM	4	0	0,00 %	0,05	3,19	311,01	Bajo rendimiento por solapamiento

Para visualizar y comparar mejor los valores de cada métrica, también se han realizado las siguientes gráficas de barras:







Por último, visualizamos de nuevo las gráficas de PCA a 2D de los cuatro modelos para una comparación final:



Varianza explicada PCA 2D:
PC1: 64.92%
PC2: 15.52%
Total: 80.43%



Varianza explicada PCA 2D:
PC1: 64.92%
PC2: 15.52%
Total: 80.43%



Una vez comparadas las métricas, y sobre todo la comparación en la **distribución y separación de clústers entre K-Means y Agglomerative**, que hemos podido observar en las **visualizaciones PCA**, podemos sacar la conclusión de que en **este caso concreto y con este dataset**, el **modelo más óptimo para la segmentación de clientes** es:

K-Means

- Es el modelo que genera la mejor distribución para los 4 clústeres, obteniendo fronteras bien definidas y sin superposición de colores, y superando la distribución de Agglomerative.
- Obtiene mejores métricas internas que Agglomerative y GMM.
- Frente a DBSCAN, K-Means no deja clientes sin asignar y ofrece una segmentación más rica y aplicable al negocio (4 clusters, frente a sólo 2 en DBSCAN).

9. Perfilado e interpretación de segmentos


El perfilado definitivo se realizó sobre las variables originales no escaladas, de modo que los valores sean directamente interpretables en términos de negocio. A cada clúster generado por K-Means se le asignó un nombre comercial basado en su perfil medio de comportamiento.

9.1 Tabla de perfil medio por segmento

Clúster	Nombre	Cientes	%	Recency	Frequency	Monetary	Ticket medio	Gasto mensual	Weekend Ratio
0	Cientes estándar de bajo valor	2.786	67,69 %	113,23	2,24	634,37	295,59	271,03	0 %
1	Cientes de compra en fin de semana	341	8,28 %	105,72	2,30	602,79	264,69	257,30	94 %
2	Cientes activos de valor medio	420	10,20 %	51,98	4,45	1.327,26	308,06	259,38	39 %
3	Cientes de alto valor	569	13,82 %	29,07	10,03	4.073,33	504,04	543,29	6 %


9.2 Distribución de clientes por segmento

Los clientes se distribuyen de forma muy asimétrica por segmento: en el clúster 0 se concentra el 67,69% de los clientes, mientras que los otros tres segmentos agrupan proporcionalmente menos clientes pero con perfiles comerciales más diferenciados y de mayor valor.



9.3 Perfil relativo de los segmentos

Con el fin de facilitar la comparación entre los distintos segmentos, hemos calculado el perfil relativo de cada clúster, normalizando las variables a una escala comparable. De este modo, los valores positivos (en rojo) indican que el segmento se sitúa por encima de la media global en esa variable, mientras que los valores negativos (en azul) reflejan que está por debajo.



Las conclusiones se pueden obtener directamente de la lectura del heatmap:

- **Clientes de bajo valor estándar:** Altos niveles de recencia (+0,93), frecuencia negativa (−0,69) y gasto negativo (−0,62). Son clientes con más tiempo sin comprar y menor actividad.
- **Clientes de fin de semana de compra:** Recency similar al cluster 0 (+0,75) pero con Weekend_Ratio muy alto (+1,38). Tienen poco valor económico pero un patrón temporal muy marcado.
- **Clientes activos de valor medio:** Ligera negatividad de la recencia (−0,56), lo que indica que han comprado más reciente que los dos segmentos anteriores. Gasto y frecuencia moderados.
- **Clientes de gran valor:** Todos los indicadores económicos altos y positivos (Frecuencia +1,44, Monetary +1,47, AverageOrderValue +1,48, MonthlySpending +1,50) y menor recencia (−1,12), lo que los sitúa como el segmento más reciente y activo.

9.4 Descripción de segmentos

Clúster 0 — Clientes estándar de bajo valor

Consta de 2.786 clientes, lo que representa el 67,69% del total segmentado. Tiene la mayor recencia promedio (113,23 días), la frecuencia de compra más baja (2,24) y un gasto medio total de 634,37 £. Son clientes con poca reincidencia, gasto moderado y mayor tiempo desde su última compra. Son la base mayoritaria de la cartera de clientes. El Weekend_Ratio es 0%, lo que indica que no tienen preferencia por comprar en fin de semana. Son candidatos a campañas de reactivación, descuentos generales y recomendaciones de productos que sean populares.

Clúster 1 — Clientes de compra en fin de semana

Formado por 341 clientes (8,28%). Y es que su rasgo diferenciador es un Weekend_Ratio medio del 94%, lo que indica que casi todas sus compras se concentran en sábado o domingo. Sin embargo, no es muy voluminoso económicamente: frecuencia 2,30 y gasto medio 602,79 £. Son mayoritariamente clientes del Reino Unido (98%).

Su valor está basado principalmente en su patrón temporal predecible, lo que permite diseñar campañas específicas de Viernes a Domingo, ofertas flash y promociones temporales.

Clúster 2 — Clientes activos de valor medio

Formado por 420 clientes (10,20%). Presenta una recencia de 51,98 días, una frecuencia de 4,45 compras y un gasto medio de 1.327,26 £, todos ellos superiores a los segmentos 0 y 1.

El PurchaseInterval de 74,35 días indica que compran con cierta recurrencia, aunque con intervalos más espaciados entre pedidos.

Tienen potencial de crecimiento y son buenos candidatos para programas de fidelización, cross-selling, up-selling y recomendaciones personalizadas.

Clúster 3 — Clientes de alto valor

Formado por 569 clientes (13,82%). Es el segmento más valioso: menor recencia media (29,07 días), mayor frecuencia (10,03 compras), mayor gasto total (4.073,33 £), mayor ticket medio (504,04 £) y mayor gasto mensual (543,29 £).

El Weekend_Ratio del 6% indica que son compradores en días laborables, lo que puede sugerir un perfil más profesional o de compra regular.

Son el segmento prioritario para estrategias de retención, programas VIP, beneficios exclusivos y atención personalizada.

9.5 Estrategias de negocio recomendadas

Segmento	Objetivo comercial	Acciones recomendadas
Estándar de bajo valor	Reactivar y aumentar recurrencia	Campañas automatizadas, descuentos moderados, recomendaciones de productos populares
Compra en fin de semana	Aprovechar patrón temporal	Ofertas flash de viernes a domingo, comunicaciones previas al fin de semana
Activos de valor medio	Convertir en alto valor	Fidelización, bundles, cross-selling, up-selling, recomendaciones personalizadas
Alto valor	Retener y proteger valor	Programa VIP, atención preferente, ofertas exclusivas y seguimiento personalizado

10. Conclusiones y líneas de mejoras

10.1 Conclusiones técnicas

El proceso completo de clustering nos permitió comparar cuatro modelos de aprendizaje no supervisado sobre el mismo conjunto de datos y con las mismas variables de entrada. La siguiente tabla resume los resultados finales de la comparativa

Modelo	Clústeres	Ruido	% ruido	Silhouette	Davies-Bouldin	Calinski-Harabasz	Valoración
K-Means	4	0	0,00 %	0,44	1,04	3.427,26	Alta: 4 segmentos accionables, mejores métricas que Agglomerative
Agglomerative	4	0	0,00 %	0,38	1,07	3.041,53	Media-alta: similar a K-Means, peores métricas
DBSCAN ajustado	2	357	8,67 %	0,70	0,33	4.362,56	Métrica alta, pero segmentación pobre y ruido
GMM	4	0	0,00 %	0,05	3,19	311,01	Bajo rendimiento por solapamiento

Las conclusiones técnicas del proceso, son las siguientes:

- Se escogió como modelo final K-Means, ya que dio el mejor equilibrio entre métricas internas, estabilidad de los clusters, ausencia de clientes no asignados e interpretabilidad comercial. Con cuatro clusters diferenciados y una Silhouette de 0,44, genera segmentos accionables sin dejar a ningún cliente fuera.
- Los perfiles generados por Agglomerative Clustering fueron similares a los de K-Means, pero con métricas inferiores (Silhouette 0,38, Calinski-Harabasz 3.041) y una distribución visual más irregular en el PCA. Sirvió como control de validez del modelo principal
- DBSCAN ajustado, aunque obtuvo mejores métricas internas (Silhouette 0,70), presenta dos problemas críticos para el objetivo del proyecto: genera únicamente dos grupos y deja fuera a 357 clientes (8,67%) considerados como ruidos. Esto lo hace menos útil para la segmentación comercial, aunque puede ser valioso como detector de anomalías.
- Se descartó GMM por presentar solapamiento extremo entre los clusters (Silhouette 0,05, Davies-Bouldin 3,19), lo que indica que las distribuciones gaussianas no se ajustan bien a la forma de los datos de este e-commerce.

10.2 Conclusiones de negocio desde el punto de vista de Marketing

Desde el punto de vista comercial, la segmentación obtenida es directamente aplicable y nos permite plantear estrategias diferenciadas para cada uno de los cuatro perfiles identificados:

- **Clientes estándar de bajo valor (67,69%):** conforman la base principal de la cartera. Aunque cada uno aporta poco, la cantidad de ellos los convierte en un segmento clave para campañas de reactivación masiva de bajo coste.

- **Clientes de compra en fin de semana (8,28 %):** conocer su patrón temporal nos permite afinar mejor el momento de impacto de las campañas, reduciendo el coste por conversión y mejorando la tasa de respuesta.
- **Clientes activos de valor medio (10,20%):** conforman un segmento con potencial de crecimiento. Con las acciones adecuadas de fidelización pueden evolucionar a perfiles de alto valor.
- **Clientes de alto valor (13,82%):** desde un punto de vista estratégico este es el segmento prioritario, ya que concentran la mayor parte del gasto y de la actividad. Es fundamental que se mantenga, ya que su pérdida afectaría de forma importante los ingresos globales.

10.3 Puntos clave a analizar

Punto	Impacto
El dataset cubre aproximadamente trece meses	Puede limitar el análisis estacional a largo plazo
Se excluyen transacciones sin CustomerID	Necesario para clustering, pero reduce la base de análisis
Los outliers se separan del modelo principal	Pueden contener clientes de alto valor pero se han identificado se ha hecho un análisis específico, eran clientes mayoristas
No se incorporan categorías de producto	La segmentación se basa en comportamiento agregado, no en preferencias de producto, queremos analizar el tipo de cliente
FavoriteDay se excluye	Se evita ruido, se pierde detalle por día concreto de compra, pero obligaría a aplicar One-Hot Encoding, aumentando la dimensionalidad del modelo

10.4 Mejoras propuestas

Mejora	Descripción
Análisis específico de outliers	Perfilar los 217 clientes separados para detectar ballenas o mayoristas
Segmentación de devoluciones	Incorporar cancelaciones para identificar clientes con alta tasa de retorno, se ha estudiado y se va a presentar un modelo
HDBSCAN	Evaluar una alternativa más robusta que DBSCAN ante densidades variables
Categorías de producto	Incluir preferencias de producto para enriquecer perfiles
Análisis temporal	Estudiar evolución mensual de los segmentos